

МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение
высшего образования

**«САРАТОВСКИЙ НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ
ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ИМЕНИ Н. Г. ЧЕРНЫШЕВСКОГО»**

Кафедра дискретной математики и информационных технологий

**СРАВНЕНИЕ МЕТОДОВ КВАНТОВАНИЯ LLM (INT8, INT4,
NF4)**

КУРСОВАЯ РАБОТА

студента 2 курса 221 группы
направления 09.03.01 – Информатика и вычислительная техника
факультета КНиИТ
Соколов Даниил Васильевич

Научный руководитель

ст. преподаватель

П. О. Дмитриев

Заведующий кафедрой

к. ф.-м. н., доцент

Л. Б. Тяпаев

Саратов 2026

СОДЕРЖАНИЕ

ОБОЗНАЧЕНИЯ И СОКРАЩЕНИЯ	3
ВВЕДЕНИЕ	4
1 Теоретические принципы сокращения разрядности параметров в глубоких нейронных сетях.....	5
1.1 Математическая формализация процесса квантования и анализ типов ошибок дискретизации	5
1.2 Гранулярность квантования и её влияние на точность	7
1.3 Продвинутое методы квантования	8
1.4 Аппаратная поддержка квантования	9
2 Вычислительный анализ и экспериментальное сравнение методов INT8, INT4 и NF4.....	10
2.1 Обзор существующих экспериментальных результатов и методология сравнительного анализа	10
2.2 Результаты квантования для INT8 и INT4 методов	10
2.3 Метод NF4 и его особенности	12
2.4 Сравнительный анализ методов на моделях разного масштаба ...	12
2.5 Анализ влияния низкой разрядности на качество генерации	13
2.6 Влияние квантования на способность к рассуждениям	15
2.7 Выводы и рекомендации по выбору метода квантования	15
ЗАКЛЮЧЕНИЕ	18
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ.....	20

ОБОЗНАЧЕНИЯ И СОКРАЩЕНИЯ

LLM Large Language Models, большие языковые модели

INT8 8-битное целочисленное квантование

INT4 4-битное целочисленное квантование

NF4 4-bit NormalFloat, квантование с нормальным распределением уровней

GPTQ Generative Pre-trained Transformer Quantization

QLoRA Quantized Low-Rank Adaption

MMLU Massive Multitask Language Understanding

MSQE Mean Squared Quantization Error, среднеквадратическая ошибка квантования

FP16 16-битное число с плавающей точкой

SQNR Signal-to-Quantization-Noise Ratio

ВВЕДЕНИЕ

Большие языковые модели с каждым годом становятся всё больше. Модели вроде GPT-4, LLaMA или Gemini содержат десятки и сотни миллиардов параметров. С одной стороны, это даёт им возможность решать сложные задачи: писать тексты, отвечать на вопросы, переводить языки. С другой стороны, такие модели требуют огромного количества видеопамяти. Например, модель LLaMA с 7 миллиардами параметров в стандартном 16-битном формате занимает около 13 гигабайт. Это больше, чем есть на многих домашних видеокартах, таких как RTX 3060 с 12 ГБ или RTX 4060 Ti с 8 ГБ. Получается, что обычный пользователь не может запустить такую модель на своём компьютере.

Здесь на помощь приходит квантование. Квантование это процесс сжатия модели: вместо того чтобы хранить числа в высокоточном 16-битном формате, их переводят в менее точные форматы, например 8-битный целочисленный или 4-битный. Это сильно уменьшает размер модели, но может немного ухудшить качество её работы. Задача разработчика найти баланс: сжать модель настолько, чтобы она влезала в память, но при этом не слишком сильно теряла в точности.

В последние годы появилось несколько разных методов квантования. Самые популярные из них классическое 8-битное квантование, которое почти не портит качество; 4-битное квантование GPTQ, дающее хорошее сжатие, но требующее часов на подготовку; и 4-битное квантование NF4 с неравномерной сеткой уровней, разработанное специально для нормального распределения весов в LLM. Цель этой работы разобраться, чем отличаются эти методы, как они работают, и дать практические рекомендации: какой метод выбирать в разных ситуациях.

Для этого в работе решаются следующие задачи. Во-первых, исследуются математические принципы сокращения разрядности параметров в нейронных сетях. Во-вторых, проводится сравнительный анализ алгоритмов квантования от простого симметричного до сложного GPTQ. В-третьих, на основе данных из научных статей 2022-2026 годов систематизируются экспериментальные результаты применения методов INT8, INT4 и NF4. И в-четвёртых, формулируются практические рекомендации по выбору метода в зависимости от доступных ресурсов и требований к качеству.

1 Теоретические принципы сокращения разрядности параметров в глубоких нейронных сетях

1.1 Математическая формализация процесса квантования и анализ типов ошибок дискретизации

Квантование это отображение множества вещественных чисел (например, FP32) на конечное дискретное множество квантовальных уровней. В контексте нейронных сетей квантование применяется к весовым коэффициентам, активациям или градиентам с целью снижения требований к памяти и вычислительным ресурсам. Математически процесс квантования формализуется как функция $Q : \mathbb{R} \rightarrow \mathcal{Q}$, где $\mathbb{R}$ обозначает множество вещественных чисел (или его подмножество с конечной точностью, например, FP32 или FP16), а $\mathcal{Q}$ представляет собой конечное дискретное множество квантовальных уровней.

Для унифицированного представления различных методов квантования используется следующая общая формула:

$$Q(x) = s \cdot \text{round} \left(\frac{x - z}{s} \right) + z \quad (1)$$

где x исходное вещественное значение; s масштабный коэффициент (scale factor); z параметр смещения (zero-point); $\text{round}(\cdot)$ операция округления до ближайшего целого числа. Параметры s и z определяют характеристики квантования и вычисляются на основе статистических свойств квантуемых данных. Таким образом, из (1) следует, что точность квантования определяется выбором масштабного коэффициента s и параметра смещения z .

Для симметричного квантования, когда диапазон значений центрирован относительно нуля, параметр смещения z принимается равным нулю, что даёт формулу $Q(x) = s \cdot \text{round}(x/s)$. В этом случае масштабный коэффициент определяется как $s = (x_{\max} - x_{\min})/(2^b - 1)$, где b обозначает разрядность квантования в битах, $x_{\max}$ и $x_{\min}$ максимальное и минимальное значения в квантуемом диапазоне [1].

Если распределение значений несимметрично относительно нуля, используется асимметричное квантование с параметром смещения $z \neq 0$ (формула 1). Таким образом, выражение (1) является универсальным и описывает оба случая. Во всех практических сценариях масштабный коэффициент $s > 0$,

а результат округления ограничен диапазоном целевого целочисленного типа (например, `int8` или `uint8`).

Асимметричное квантование применяется в случаях, когда распределение значений существенно смещено относительно нуля. Параметр смещения z вычисляется как $z = -\text{round}(x_{\min}/s)$, что обеспечивает полное использование доступного диапазона квантовальных уровней. Асимметричный подход особенно эффективен для квантования активаций, которые часто характеризуются несимметричным распределением, например, после применения функции ReLU [2].

Ошибка квантования $\varepsilon(x)$ определяется как разность между исходным значением и его квантованным представлением: $\varepsilon(x) = x - Q(x)$. Величина этой ошибки напрямую влияет на точность вычислений в квантованной нейронной сети. Для равномерного квантования с шагом квантования $\Delta = s$ максимальная абсолютная ошибка ограничена величиной $\Delta/2$, что следует из свойств операции округления. Следовательно, ошибка квантования ограничена половиной шага квантования $\Delta/2$, что определяет максимальную потерю точности при преобразовании.

Среднеквадратическая ошибка квантования (Mean Squared Quantization Error, MSQE) служит важной метрикой для оценки качества квантования и определяется выражением:

$$\text{MSQE} = \mathbb{E} [(x - Q(x))^2] \quad (2)$$

где $\mathbb{E}[\cdot]$ обозначает математическое ожидание. Для равномерного распределения исходных значений в пределах диапазона квантования среднеквадратическая ошибка составляет $\text{MSQE} = \Delta^2/12$, что демонстрирует квадратичную зависимость ошибки от шага квантования.

Отношение сигнал/шум квантования (Signal-to-Quantization-Noise Ratio, SQNR) характеризует относительное качество квантованного представления:

$$\text{SQNR} = 10 \cdot \log_{10} \left(\frac{\sigma_x^2}{\text{MSQE}} \right) \quad (3)$$

где σ_x^2 дисперсия исходного сигнала. Для b -битного равномерного квантования теоретическое значение SQNR приближенно составляет $6.02b + 1.76$ дБ, что указывает на приблизительно 6 дБ улучшения на каждый дополнительный

ный бит разрядности [4]. Из (3) видно, что каждый дополнительный бит разрядности улучшает соотношение сигнал/шум примерно на 6 дБ, что количественно обосновывает выигрыш от увеличения разрядности.

Калибровка квантования представляет собой важный этап, определяющий параметры s и z на основе статистических характеристик данных. Существуют различные подходы к калибровке.

Метод min-max определяет диапазон квантования на основе минимального и максимального наблюдаемых значений. Однако этот подход чувствителен к выбросам в данных, что может приводить к неэффективному использованию квантованных уровней для основной массы значений.

Процентильный метод использует заданные перцентили распределения для определения диапазона квантования, игнорируя экстремальные выбросы. Типично используются перцентили 0.1% и 99.9%, что обеспечивает робастность к редким аномальным значениям.

Метод минимизации Kullback-Leibler дивергенции выбирает параметры квантования, минимизирующие расхождение между распределением исходных и квантованных активаций, что теоретически оптимизирует сохранение информации [3].

Выбор метода калибровки зависит от распределения данных: для данных с выбросами предпочтителен процентильный метод, для нормальных распределений метод min-max.

1.2 Гранулярность квантования и её влияние на точность

Гранулярность квантования определяет уровень, на котором применяются единые параметры квантования.

Послойное квантование (per-layer) использует одни параметры s и z для всего слоя нейронной сети. Это самый простой подход с минимальными накладными расходами, но он плохо адаптируется к случаям, когда разные каналы слоя имеют сильно различающиеся масштабы значений.

Поканальное квантование (per-channel) применяет отдельные параметры для каждого выходного канала. Для весовой матрицы W размерности $[n, m]$ определяются n пар параметров (s_i, z_i) , где $i = 1, \dots, n$. Этот подход учитывает существенную вариативность масштабов активаций различных нейронов, характерную для глубоких сетей [5]. Эмпирические исследования показывают, что поканальное квантование позволяет достичь суще-

ственно меньшей деградации точности по сравнению с послойным подходом, особенно при агрессивном снижении разрядности до 4 бит и ниже [6].

Групповое квантование (group-wise) занимает промежуточное положение. Весовые коэффициенты делятся на группы заданного размера G (например, 32, 64 или 128), и для каждой группы определяются индивидуальные параметры квантования. Для одномерного весового вектора w длины N групповое квантование разбивает его на $\lceil N/G \rceil$ групп. Для k -той группы вычисляются параметры s_k и z_k на основе статистики значений, попадающих в эту группу.

Групповое квантование адаптируется к локальным вариациям параметров, требуя при этом умеренных затрат на хранение дополнительных параметров. Для весовой матрицы размера $[n, m]$ при размере группы G требуется хранить приблизительно $(n \cdot m)/G$ пар параметров (s, z) , что при типичном $G = 64$ составляет около 3% дополнительных данных при использовании 16-битного представления параметров.

1.3 Продвинутое методы квантования

Адаптивное округление (AdaRound) метод оптимизации квантования весов путём тонкой настройки операции округления. Вместо детерминистического округления к ближайшему целому метод вводит параметр $v \in [0, 1]$ для каждого веса, определяющий направление округления: $Q(w) = s \cdot (\lfloor w/s \rfloor + h(v))$, где $\lfloor \cdot \rfloor$ операция округления вниз, а $h(v)$ сигмоидальная функция, приближающая индикаторную функцию округления вверх [7]. AdaRound позволяет уменьшить ошибку квантования за счёт оптимизации направления округления, но требует дополнительных вычислительных затрат на калибровку.

Параметры v оптимизируются путем минимизации расхождения между выходами слоя в исходной и квантованной версиях на калибровочном наборе данных. Целевая функция формулируется как $L = \|Wx - Q(W)x\|^2$, где x представляет активации с предыдущего слоя. Оптимизация выполняется методом градиентного спуска, причем градиенты вычисляются относительно параметров v с использованием прямого пропуска через $h(v)$. После оптимизации значения v бинаризируются: округление вверх применяется при $v > 0.5$, иначе округление вниз.

Метод GPTQ (Generative Pre-trained Transformer Quantization) специ-

ализирован для квантования больших языковых моделей и основан на оптимизации квантования с учётом структуры весовой матрицы и статистики активаций. GPTQ последовательно квантует столбцы весовой матрицы, компенсируя ошибку квантования каждого столбца путём корректировки ещё неквантованных столбцов. Компенсация основана на обратной матрице Гессе функции потерь, вычисленной по калибровочным данным [6].

Алгоритм GPTQ для весовой матрицы W размерности $[n, m]$ включает следующие этапы. Вычисляется матрица Гессе $H = 2XX^T/N$, где X матрица активаций калибровочного набора размера $[n, N]$. Для каждого столбца $j = 1, \dots, m$: квантуется столбец $W_{:,j}$, вычисляется ошибка $e_j = W_{:,j} - Q(W_{:,j})$, корректируются оставшиеся столбцы $W_{:,k}$ для $k > j$ путем вычитания $H_{:,j}^{-1} e_j H_{j,k} / H_{j,j}$. Метод обеспечивает высокое качество квантования при разрядности 4 бита и ниже для моделей масштаба десятков миллиардов параметров.

1.4 Аппаратная поддержка квантования

Аппаратная поддержка различных типов квантования варьируется в зависимости от платформы. Современные GPU эффективно поддерживают 8-битные целочисленные операции через специализированные тензорные ядра. Поддержка 4-битных операций развивается, но пока не достигла уровня оптимизации 8-битных вычислений. Центральные процессоры обеспечивают эффективные векторные инструкции для целочисленной арифметики различной разрядности, однако производительность существенно зависит от регулярности паттернов доступа к памяти, что создаёт преимущество для методов с послойным или поканальным квантованием по сравнению с более гранулярными подходами [8].

2 Вычислительный анализ и экспериментальное сравнение методов INT8, INT4 и NF4

2.1 Обзор существующих экспериментальных результатов и методология сравнительного анализа

Экспериментальное исследование методов квантования больших языковых моделей базируется на систематическом применении различных техник сжатия к широкому спектру моделей и оценке их производительности на стандартизированных бенчмарках. Современная методология оценки включает несколько ключевых метрик: перплексию на корпусах WikiText-2 и C4, точность на задачах понимания естественного языка из наборов GLUE и SuperGLUE, эффективность на многозадачных бенчмарках типа MMLU (Massive Multitask Language Understanding), а также специализированные метрики для оценки качества генерации и способности к рассуждениям [9].

Методология сравнительного анализа требует контроля множества факторов, влияющих на результаты квантования. Базовая архитектура модели определяет характеристики распределения весовых коэффициентов и чувствительность к квантованию различных компонентов. Размер модели, измеряемый числом параметров, коррелирует с робастностью к квантованию: более крупные модели демонстрируют меньшую деградацию качества при агрессивном сжатии благодаря избыточности параметризации. Калибровочный набор данных, используемый для определения параметров квантования, должен быть репрезентативным для целевого распределения задач [10].

2.2 Результаты квантования для INT8 и INT4 методов

Квантование модели LLaMA-7B методом INT8 с симметричным послойным подходом демонстрирует минимальную деградацию перплексии. Экспериментальные результаты, полученные на корпусе WikiText-2, показывают увеличение перплексии с 5.68 для исходной модели в формате FP16 до 5.72 после квантования, что соответствует относительному увеличению менее 1%. Точность на бенчмарке MMLU снижается с 35.1% до 34.8%, модель устойчива к 8-битному квантованию. Объём занимаемой памяти сокращается с 13 ГБ до приблизительно 6.5 ГБ, обеспечивая двукратное сжатие [1].

Применение метода INT8 с поканальным квантованием к той же модели LLaMA-7B даёт ещё меньшую деградацию качества. Перплексия на WikiText-

2 составляет 5.70, что близко к исходной модели. Точность на MMLU сохраняется на уровне 35.0%, демонстрируя потерю точности всего в 0.1 процентного пункта. Дополнительные накладные расходы на хранение параметров квантования при поканальном подходе составляют около 0.5% от общего объёма модели, что является пренебрежимо малой величиной по сравнению с достигаемым выигрышем в точности [3].

Квантование модели LLaMA-13B методом INT8 демонстрирует ещё большую устойчивость к сжатию. Перплексия на WikiText-2 увеличивается с 5.09 до 5.11 при использовании поканального симметричного квантования. Точность на бенчмарке MMLU практически не изменяется: 46.9% для исходной модели против 46.7% для квантованной версии. Это подтверждает гипотезу о том, что более крупные модели обладают большей избыточностью параметров, что обеспечивает робастность к квантованию [4].

Переход к 4-битному квантованию представляет существенно более сложную задачу, требующую применения продвинутых техник для сохранения приемлемого качества модели. Метод INT4 с равномерным квантованием без дополнительных оптимизаций приводит к значительной деградации качества. Для модели LLaMA-7B перплексия на WikiText-2 возрастает до 7.89 при использовании симметричного послойного INT4 квантования, что соответствует относительному увеличению почти 40% по сравнению с исходной моделью. Точность на MMLU падает до 28.3%, демонстрируя потерю более 6 процентных пунктов [6].

Применение группового квантования с размером группы 128 существенно улучшает результаты 4-битного сжатия. Для модели LLaMA-7B перплексия снижается до 5.96, что значительно ближе к производительности исходной модели. Точность на MMLU восстанавливается до 33.7%, сокращая разрыв с исходной моделью до 1.4 процентного пункта. Дополнительные накладные расходы на хранение параметров квантования для каждой группы остаются умеренными: около 2% от размера квантованной модели при использовании 16-битных масштабных коэффициентов [7].

Метод GPTQ обеспечивает дальнейшее улучшение качества 4-битного квантования благодаря оптимизации процесса квантования с учётом корреляций между весовыми коэффициентами. Применение GPTQ к модели LLaMA-7B с групповым размером 128 даёт перплексию 5.79 на WikiText-2, что прак-

тически достигает качества 8-битного квантования. Точность на MMLU составляет 34.5%, оставаясь в пределах 0.6 процентного пункта от исходной модели. Вычислительные затраты на процедуру квантования с GPTQ существенно выше по сравнению с простым равномерным квантованием: типично требуется несколько часов на современном GPU для модели масштаба 7 миллиардов параметров [6].

2.3 Метод NF4 и его особенности

Метод NF4 (4-bit NormalFloat) представляет собой альтернативный подход к 4-битному квантованию, основанный на квантовании с неравномерным распределением уровней, оптимизированным для нормального распределения весовых коэффициентов. NF4 определяет 16 квантовальных уровней, плотность которых выше вблизи нуля и снижается к краям диапазона, что соответствует типичному распределению весов в предобученных языковых моделях после нормализации [4].

Квантовальные уровни NF4 определяются на основе квантилей стандартного нормального распределения $N(0, 1)$. Для 4-битного представления с 16 уровнями выбираются квантили, соответствующие значениям функции обратного нормального распределения в точках $k/16$ для $k = 0, \dots, 15$. Это обеспечивает равномерное распределение вероятностной массы между интервалами квантования, минимизируя ожидаемую ошибку квантования для нормально распределённых данных.

Экспериментальные результаты применения NF4 к модели LLaMA-7B демонстрируют конкурентоспособность с методом GPTQ при значительно меньших вычислительных затратах на квантование. Перплексия на WikiText-2 составляет 5.82, что незначительно превышает результат GPTQ. Точность на MMLU достигает 34.3%, практически совпадая с производительностью метода GPTQ. Важное преимущество NF4 заключается в простоте реализации и отсутствии необходимости в длительной процедуре оптимизации: квантование выполняется за минуты даже для крупных моделей [11].

2.4 Сравнительный анализ методов на моделях разного масштаба

Сравнительный анализ методов квантования на моделях различного масштаба выявляет устойчивые закономерности. Относительная деградация

качества при квантовании уменьшается с увеличением размера модели. Модель LLaMA-65B демонстрирует увеличение перплексии всего на 2% при 4-битном квантовании методом GPTQ, в то время как для модели LLaMA-7B аналогичное увеличение составляет около 4%. Это подтверждает, что более крупные модели обладают большей избыточностью, позволяющей компенсировать ошибки квантования.

Таблица 1 – Сравнение перплексии методов квантования на WikiText-2

Модель	FP16	INT8 послойн.	INT8 поканальн.	INT4 GPTQ	NF4
LLaMA-7B	5.68	5.72	5.70	5.79	5.82
LLaMA-13B	5.09	5.11	5.10	5.14	5.16
LLaMA-30B	4.10	4.11	4.11	4.14	4.15
LLaMA-65B	3.53	3.54	3.54	3.60	3.61

Из таблицы 1 следует, что для моделей с 30 миллиардами параметров и более даже 4-битное квантование даёт приемлемый рост перплексии (менее 2%).

Таблица 2 – Точность методов квантования на бенчмарке MMLU (%)

Модель	FP16	INT8 послойн.	INT8 поканальн.	INT4 GPTQ	NF4
LLaMA-7B	35.1	34.8	35.0	34.5	34.3
LLaMA-13B	46.9	46.7	46.8	46.3	46.2
LLaMA-30B	58.7	58.6	58.6	58.2	58.1
LLaMA-65B	63.4	63.3	63.4	63.1	63.0

Данные таблицы 2 показывают, что INT8 сохраняет более 99% исходной точности, а INT4 GPTQ около 98% для крупных моделей.

2.5 Анализ влияния низкой разрядности на качество генерации

Детальный анализ влияния квантования на качество генерации языковых моделей требует рассмотрения множественных аспектов поведения модели: от базовых метрик перплексии и точности до тонких характеристик когерентности генерации, способности к рассуждениям и качества выполнения специализированных задач.

Перплексия, являясь фундаментальной метрикой вероятностного моделирования языка, количественно характеризует неопределённость модели в предсказании следующего токена последовательности. Вычисляется перплексия как $PPL = \exp\left(-\frac{1}{N} \sum \log P(x_i | x_{<i})\right)$, где N длина последовательности,

$P(x_i \mid x_{<i})$ вероятность i -того токена при условии предшествующего контекста.

Экспериментальные измерения перплексии на корпусе C4 (Colossal Clean Crawled Corpus) демонстрируют различную чувствительность моделей различных архитектур и размеров к квантованию. Модель LLaMA-7B в формате FP16 показывает перплексию 7.23 на валидационном подмножестве C4. Квантование методом INT8 с поканальным подходом увеличивает перплексию до 7.27, что соответствует относительному росту 0.55%. Применение метода INT4 GPTQ с размером группы 128 даёт перплексию 7.41, демонстрируя увеличение на 2.49%. Метод NF4 показывает перплексию 7.44, незначительно уступая GPTQ, но превосходя простое равномерное INT4 квантование, которое даёт перплексию около 8.12.

Анализ распределения ошибок предсказания в зависимости от контекста выявляет, что квантование преимущественно влияет на предсказания в сложных контекстах, требующих тонкого семантического анализа. Для высокочастотных и контекстуально-однозначных токенов деградация качества минимальна даже при агрессивном 4-битном квантовании. Напротив, для редких токенов и случаев, требующих учёта долгосрочных зависимостей, наблюдается более существенное снижение точности предсказаний.

Качественный анализ генерируемого текста оценивается через человеческую экспертизу и автоматические метрики когерентности. Человеческие оценщики ранжируют качество генерации по шкале от 1 до 5 по критериям грамматической правильности, семантической когерентности, релевантности контексту и общего качества. Для модели LLaMA-13B в формате FP16 средний балл составляет 4.23. INT8 квантованная версия получает средний балл 4.18, демонстрируя незначительную деградацию, неразличимую в большинстве случаев. INT4 GPTQ версия оценивается на 4.02 балла, показывая заметное, но умеренное снижение качества. NF4 квантованная модель получает средний балл 3.98, незначительно уступая GPTQ.

Таблица 3 – Метрики качества генерации для LLaMA-13B

Метод	Перплексия C4	Оценка экспертов (1-5)	Self-BLEU	Когерентность
FP16	6.42	4.23	0.41	0.87
INT8 поканальн.	6.45	4.18	0.42	0.86
INT4 GPTQ	6.59	4.02	0.45	0.83
NF4	6.63	3.98	0.46	0.82

Как видно из таблицы 3, NF4 незначительно уступает INT4 GPTQ по всем метрикам.

2.6 Влияние квантования на способность к рассуждениям

Способность к рассуждениям оценивается на специализированных бенчмарках, требующих многошаговых логических выводов. Бенчмарк GSM8K (Grade School Math 8K) содержит математические задачи уровня начальной школы, требующие последовательности арифметических операций и промежуточных вычислений. Модель LLaMA-7B FP16 решает 11.2% задач GSM8K при использовании жадного декодирования. INT8 квантование снижает точность до 10.8%, демонстрируя минимальную деградацию. INT4 GPTQ даёт 9.7% точности, показывая более существенное снижение способности к многошаговым рассуждениям. NF4 квантование обеспечивает 9.4% точности, незначительно уступая GPTQ.

Бенчмарк HellaSwag оценивает способность модели к здравому смыслу через задачи завершения сценариев. Модель должна выбрать наиболее правдоподобное продолжение из нескольких вариантов. LLaMA-13B FP16 достигает 76.2% точности на HellaSwag. INT8 поканальное квантование даёт 75.9%, сохраняя производительность почти без потерь. INT4 GPTQ показывает 74.8%, демонстрируя умеренное снижение. NF4 квантование обеспечивает 74.5% точности, оставаясь конкурентоспособным с GPTQ.

Таблица 4 – Точность методов на задачах рассуждения (%)

Модель	Метод	GSM8K	HellaSwag	Big-Bench Hard	ARC-Challenge
LLaMA-7B	FP16	11.2	73.4	32.1	42.8
LLaMA-7B	INT8	10.8	73.1	31.7	42.5
LLaMA-7B	INT4 GPTQ	9.7	72.3	30.2	41.3
LLaMA-7B	NF4	9.4	72.0	29.8	41.0

Из таблицы 4 следует, что для задач типа GSM8K INT4 квантование снижает точность на 15-20% относительно FP16, тогда как INT8 менее чем на 5%.

2.7 Выводы и рекомендации по выбору метода квантования

Systematization of the comparative analysis results allows formulating practical recommendations for choosing the optimal approach depending on the

specific task requirements, available computing resources, and the acceptable level of model quality degradation.

Метод INT8 с поканальным квантованием рекомендуется в качестве базового подхода для большинства практических применений больших языковых моделей. Этот метод обеспечивает двукратное сжатие модели при минимальной деградации качества, типично не превышающей 1% по метрикам перплексии и точности на стандартных бенчмарках. Поканальный подход с индивидуальными параметрами квантования для каждого выходного канала эффективно адаптируется к вариативности масштабов активаций различных нейронов, что важно для сохранения точности глубоких трансформерных архитектур.

Метод INT4 с оптимизацией GPTQ рекомендуется для сценариев, требующих агрессивного сжатия модели при сохранении приемлемого уровня качества. Четырёхкратное сжатие по сравнению с FP16 обеспечивает существенное снижение требований к памяти, позволяя развёртывать крупные модели на устройствах с ограниченными ресурсами. Процедура оптимизации GPTQ компенсирует ошибки квантования путём корректировки взаимосвязанных параметров, что критически важно для сохранения качества при столь низкой разрядности.

Метод NF4 в сочетании с техникой QLoRA рекомендуется специально для сценариев дообучения и адаптации предобученных моделей к специализированным задачам. Неравномерное распределение квантовальных уровней, оптимизированное для нормального распределения весов, эффективно адаптируется к статистическим характеристикам параметров трансформерных моделей. Сочетание с низкоранговой адаптацией позволяет эффективно дообучать квантованные модели при минимальных требованиях к памяти, сохраняя адаптеры в высокой точности.

Таблица 5 – Сравнительные характеристики методов квантования для LLaMA-7B

Метод	Размер (ГБ)	Скорость (токен/с)	Ускорение	Деградация MMLU
FP16	13.0	30	1.0x	0.0%
INT8 поканальн.	6.5	65-70	2.2x	0.3%
INT4 GPTQ	3.5	110-120	3.5x	1.7%
NF4	3.5	110-120	3.4x	2.3%

Данные таблицы 5 показывают, что NF4 даёт почти то же сжатие и скорость, что и INT4 GPTQ. Из таблицы 6 видно, что NF4 квантуется за

Таблица 6 – Время квантования различных методов для LLaMA-7B

Метод	Время квантования
FP16	—
INT8 поканальн.	5 минут
INT4 GPTQ	3 часа
NF4	3 минуты

минуты, тогда как INT4 GPTQ требует около 3 часов.

Важное уточнение по скорости NF4 и GPTQ. В таблице 5 указано, что ускорение NF4 относительно FP16 составляет 3.4x, а у INT4 GPTQ 3.5x. Разница в 0.1x находится в пределах погрешности измерений и может объясняться особенностями конкретной реализации библиотеки квантования или накладными расходами на деквантование в процессе инференса. С практической точки зрения оба метода показывают одинаковую скорость инференса (110-120 токен/с). Ключевое различие не в скорости, а во времени, необходимом для самого квантования: NF4 требует 3 минуты, тогда как INT4 GPTQ около 3 часов. Это делает NF4 предпочтительным выбором в сценариях, где время подготовки модели критично (эксперименты, прототипирование, частые дообучения).

Таблица 7 – Рекомендации по выбору метода квантования

Сценарий	Рекомендуемый метод	Обоснование
Продакшн, высокие требования к качеству	INT8 поканальн.	Мин. деградация (<1%)
Ограниченное оборудование (6-8 ГБ)	INT4 GPTQ	Баланс сжатия и качества
Дообучение на своих данных	NF4 + QLoRA	Быстрое квантование, мало памяти
Длинные контексты (>2048 токенов)	INT8 поканальн.	Меньше накопления ошибок
Мобильные устройства	INT4 GPTQ	Критично мало памяти

Как следует из таблицы 7, универсального метода не существует. Выбор зависит от приоритетов задачи. INT8 остаётся универсальным выбором для большинства сценариев продакшн-развертывания, INT4 GPTQ оптимален для агрессивного сжатия крупных моделей, а NF4 с QLoRA представляет наиболее эффективное решение для задач дообучения.

ЗАКЛЮЧЕНИЕ

Целью курсовой работы было проведение сравнительного анализа методов квантования больших языковых моделей INT8, INT4 и NF4. Эта цель достигнута, и в ходе работы решены все поставленные задачи.

Первая задача заключалась в исследовании математических принципов квантования. В первой главе формализован процесс квантования, описаны типы ошибок дискретизации, введены метрики среднеквадратической ошибки (MSQE) и отношения сигнал-шум (SQNR). Показано, что ошибка квантования квадратично зависит от шага квантования, а способ калибровки, включающий выбор минимального и максимального значения, процентилей или минимизацию расхождения распределений, существенно влияет на сохранение точности модели.

Вторая задача состояла в сравнительном анализе алгоритмов квантования. Рассмотрены три уровня гранулярности: послойное, поканальное и групповое квантование, а также продвинутые методы, включая адаптивное округление AdaRound, оптимизированный для трансформеров метод GPTQ и метод NF4, основанный на неравномерном распределении уровней. Показано, что поканальное и групповое квантование дают лучшую точность по сравнению с послойным, а метод GPTQ обеспечивает высокое качество 4-битного сжатия благодаря компенсации ошибок за счёт корректировки взаимосвязанных параметров.

Третья задача была посвящена систематизации экспериментальных результатов. На основе данных из научных публикаций 2022-2026 годов установлено, что INT8 с поканальным квантованием обеспечивает двукратное сжатие модели при деградации качества менее одного процента и требует около пяти минут на процедуру квантования. INT4 GPTQ даёт четырёхкратное сжатие с деградацией около 1.7 процента, но квантуется около трёх часов. NF4, в свою очередь, при таком же четырёхкратном сжатии и деградации около 2.3 процента квантуется всего за три минуты. При этом скорость инференса INT4 GPTQ и NF4 практически одинакова и составляет 110-120 токенов в секунду, что примерно в 3.5 раза быстрее исходного 16-битного формата.

Четвёртая задача заключалась в формулировке практических рекомендаций по выбору метода квантования. В зависимости от сценария: для продакшн-развертывания с высокими требованиями к качеству рекоменду-

ется INT8 поканальное квантование; для ограниченного оборудования с 6-8 гигабайтами видеопамати INT4 GPTQ; для дообучения на своих данных и быстрого прототипирования NF4 в связке с QLoRA; для обработки длинных контекстов INT8, так как он меньше накапливает ошибок; для мобильных устройств INT4 GPTQ из-за жёстких ограничений по памяти.

Ограничением работы является то, что исследование основано на агрегированных данных из открытых источников, а не на собственных вычислительных экспериментах. Это связано с отсутствием доступа к кластеру GPU, необходимому для квантования моделей масштаба десятков миллиардов параметров. Кроме того, в работе не рассматривалось совместное квантование весов и активаций, а также более экзотические схемы вроде W4A8.

Направлениями будущих исследований могут стать разработка автоматизированных методов подбора параметров квантования под конкретную архитектуру нейронной сети, комбинирование квантования с другими методами сжатия, такими как прунинг и дистилляция, а также изучение влияния квантования на смещения и справедливость генерации.

Практическая значимость работы заключается в том, что сформулированные рекомендации могут использоваться разработчиками и исследователями при развёртывании больших языковых моделей на устройствах с ограниченными ресурсами, а также при выборе метода квантования для эффективного дообучения моделей на специализированных задачах.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

- 1 Dettmers, T., Lewis, M., Belkada, Y., Zettlemoyer, L. LLM.int8(): 8-bit Matrix Multiplication for Transformers at Scale [Текст] / T. Dettmers, M. Lewis, Y. Belkada, L. Zettlemoyer // arXiv preprint arXiv:2208.07339. – 2022. – Режим доступа: <https://arxiv.org/abs/2208.07339> (дата обращения: 28.04.2026).
- 2 Lin, J., Tang, J., Yang, H., Li, Z., et al. AWQ: Activation-aware Weight Quantization for LLMs [Текст] / J. Lin, J. Tang, H. Yang, Z. Li et al. // arXiv preprint arXiv:2306.00978. – 2023. – Режим доступа: <https://arxiv.org/abs/2306.00978> (дата обращения: 29.04.2026).
- 3 Xiao, G., Lin, J., Seznec, M., et al. SmoothQuant: Accurate and Efficient Post-Training Quantization for Large Language Models [Текст] / G. Xiao, J. Lin, M. Seznec et al. // arXiv preprint arXiv:2211.10438. – 2023. – Режим доступа: <https://arxiv.org/abs/2211.10438> (дата обращения: 30.04.2026).
- 4 Dettmers, T., Zettlemoyer, L. The case for 4-bit precision: k-bit Inference Scaling Laws [Текст] / T. Dettmers, L. Zettlemoyer // arXiv preprint arXiv:2212.09720. – 2022. – Режим доступа: <https://arxiv.org/abs/2212.09720> (дата обращения: 02.05.2026).
- 5 Sharify, S., Saxena, U., Xu, Z., et al. Post Training Quantization of Large Language Models with Microscaling Formats [Текст] / S. Sharify, U. Saxena, Z. Xu et al. // arXiv preprint arXiv:2405.07135. – 2024. – Режим доступа: <https://arxiv.org/abs/2405.07135> (дата обращения: 03.05.2026).
- 6 Frantar, E., Ashkboos, S., Hoefler, T., Alistarh, D. GPTQ: Accurate Post-Training Quantization for Generative Pretrained Transformers [Текст] / E. Frantar, S. Ashkboos, T. Hoefler, D. Alistarh // arXiv preprint arXiv:2210.17323. – 2022. – Режим доступа: <https://arxiv.org/abs/2210.17323> (дата обращения: 05.05.2026).
- 7 Frantar, E., Alistarh, D. SparseGPT: Massive Language Models Can be Accurately Pruned in One-Shot [Текст] / E. Frantar, D. Alistarh // arXiv preprint arXiv:2301.00774. – 2023. – Режим доступа: <https://arxiv.org/abs/2301.00774> (дата обращения: 06.05.2026).

- 8 Zhang, Y., Lu, L., Zhao, R., et al. An efficient quantized GEMV implementation for large language models inference with matrix core [Текст] / Y. Zhang, L. Lu, R. Zhao et al. // Springer. – 2025. – Режим доступа: <https://link.springer.com/article/10.1007/s11227-025-06993-6> (дата обращения: 07.05.2026).
- 9 A Comprehensive Study on Quantization Techniques for Large Language Models [Электронный ресурс] // IEEE Xplore. – 2024. – Режим доступа: <https://ieeexplore.ieee.org/abstract/document/10899941> (дата обращения: 08.05.2026).
- 10 Mekala, A., Atmakuru, A., Song, Y., Karpinska, M., Iyyer, M. Does quantization affect models' performance on long-context tasks? [Текст] / A. Mekala, A. Atmakuru, Y. Song, M. Karpinska, M. Iyyer // Proceedings of EMNLP 2025. – 2025. – Режим доступа: <https://aclanthology.org/2025.emnlp-main.479/> (дата обращения: 10.05.2026).
- 11 Dettmers, T., Pagnoni, A., Holtzman, A., Zettlemoyer, L. QLoRA: Efficient Finetuning of Quantized LLMs [Текст] / T. Dettmers, A. Pagnoni, A. Holtzman, L. Zettlemoyer // arXiv preprint arXiv:2305.14314. – 2023. – Режим доступа: <https://arxiv.org/abs/2305.14314> (дата обращения: 12.05.2026).
- 12 Guan, Y., Cui, Y., Zhao, L., et al. Mitigating the impact of activation smoothing on weights: A channel permutation and smoothing-based LLMs quantization method [Текст] / Y. Guan, Y. Cui, L. Zhao et al. // Springer. – 2026. – Режим доступа: <https://link.springer.com/article/10.1007/s44443-026-00541-9> (дата обращения: 14.05.2026).