

МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение
высшего образования

**«САРАТОВСКИЙ НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ
ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ИМЕНИ Н. Г. ЧЕРНЫШЕВСКОГО»**

Кафедра дискретной математики и информационных технологий

**СРАВНЕНИЕ МЕТОДОВ КВАНТОВАНИЯ LLM (INT8, INT4,
NF4)**

КУРСОВАЯ РАБОТА

студента 2 курса 221 группы
направления 09.03.01 – Информатика и вычислительная техника
факультета КНиИТ
Соколов Даниил Васильевич

Научный руководитель

ст. преподаватель

П. О. Дмитриев

Заведующий кафедрой

к. ф.-м. н., доцент

Л. Б. Тяпаев

Саратов 2026

СОДЕРЖАНИЕ

ОБОЗНАЧЕНИЯ И СОКРАЩЕНИЯ	3
ВВЕДЕНИЕ	4
1 Теоретические принципы сокращения разрядности параметров в глубоких нейронных сетях.....	7
1.1 Математическая формализация процесса квантования и анализ типов ошибок дискретизации	7
1.2 Гранулярность квантования и её влияние на точность	9
1.3 Продвинутое методы квантования	10
1.4 Аппаратная поддержка квантования	11
2 Вычислительный анализ и экспериментальное сравнение методов INT8, INT4 и NF4.....	12
2.1 Обзор существующих экспериментальных результатов и методология сравнительного анализа	12
2.2 Результаты квантования для INT8 и INT4 методов	12
2.3 Метод NF4 и его особенности	14
2.4 Сравнительный анализ методов на моделях разного масштаба ...	14
2.5 Анализ влияния низкой разрядности на качество генерации	15
2.6 Влияние квантования на способность к рассуждениям	17
2.7 Выводы и рекомендации по выбору метода квантования	18
ЗАКЛЮЧЕНИЕ	21
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ.....	23

ОБОЗНАЧЕНИЯ И СОКРАЩЕНИЯ

LLM Large Language Models, большие языковые модели

INT8 8-битное целочисленное квантование

INT4 4-битное целочисленное квантование

NF4 4-bit NormalFloat, квантование с нормальным распределением уровней

GPTQ Generative Pre-trained Transformer Quantization

QLoRA Quantized Low-Rank Adaption

MMLU Massive Multitask Language Understanding

MSQE Mean Squared Quantization Error, среднеквадратическая ошибка квантования

FP16 16-битное число с плавающей точкой

SQNR Signal-to-Quantization-Noise Ratio

ВВЕДЕНИЕ

Число параметров больших языковых моделей (Large Language Models, LLM) быстро увеличивается, что повышает требования к вычислительным ресурсам при обучении и инференсе. Модели, содержащие миллиарды параметров, показывают высокие результаты в решении разнообразных задач обработки естественного языка, однако их практическое применение ограничивается высокими требованиями к оперативной памяти и вычислительным ресурсам. В этом контексте методы квантования являются важным направлением оптимизации, позволяющим снизить разрядность представления весовых коэффициентов и активаций при сохранении приемлемого уровня точности модели.

Актуальность исследования методов квантования обусловлена несколькими факторами. Во-первых, необходимость развёртывания LLM на устройствах с ограниченными ресурсами требует разработки эффективных методов сжатия моделей. Во-вторых, экономическая эффективность применения LLM в промышленности связана с оптимизацией вычислительных затрат. В-третьих, энергопотребление крупных нейросетевых систем является значимым фактором при их промышленном внедрении.

Методы квантования нейронных сетей исследуются с начала 2010-х годов. Первые работы были посвящены в основном свёрточным архитектурам для задач компьютерного зрения. Однако специфика трансформерных архитектур, лежащих в основе современных LLM, требует адаптации классических подходов к сжатию моделей. Распределение весовых коэффициентов в языковых моделях характеризуется наличием выбросов и несимметричностью, что существенно усложняет применение традиционных методов равномерного квантования.

Несмотря на активные исследования последних лет, некоторые вопросы квантования языковых моделей остаются недостаточно изученными. К дискуссионным вопросам относятся оптимальный баланс между степенью сжатия модели и деградацией ее производительности, выбор оптимальной гранулярности квантования, а также влияние различных методов на специфические аспекты поведения модели, такие как способность к рассуждениям и генерации длинных контекстов. Требуется разработка унифицированной методологии выбора метода квантования в зависимости от целевой задачи и

аппаратных ограничений.

Цель курсовой работы состоит в проведении сравнительного анализа методов квантования больших языковых моделей INT8, INT4 и NF4 с точки зрения их влияния на качество генерации, вычислительную эффективность и применимость к различным типам задач.

Для достижения поставленной цели необходимо решить следующие **задачи**:

- исследовать математические принципы сокращения разрядности параметров в глубоких нейронных сетях и формализовать типы ошибок дискретизации;
- провести сравнительный анализ алгоритмов целочисленного квантования от симметричного до поблочного подходов;
- систематизировать существующие экспериментальные результаты применения методов INT8, INT4 и NF4 к современным языковым моделям;
- проанализировать влияние низкоразрядного квантования на ключевые метрики качества и сформулировать рекомендации по выбору метода.

Объектом исследования выступают большие языковые модели трансформерной архитектуры и методы их оптимизации.

Предметом исследования являются методы квантования весовых коэффициентов LLM с различной разрядностью представления: INT8, INT4 и NF4.

Теоретическую базу исследования составляют фундаментальные концепции теории информации, численных методов и оптимизации нейронных сетей. Математический аппарат работы опирается на теорию квантования сигналов, статистическую теорию оценивания и линейную алгебру. Методологической основой служат работы по архитектуре трансформеров, механизмам внимания и методам компрессии нейросетевых моделей.

Методы исследования включают аналитические методы исследования алгоритмов квантования, численное моделирование процессов дискретизации весовых коэффициентов, сравнительный анализ экспериментальных результатов из научных публикаций и технических отчетов, статистические методы обработки данных бенчмарков. Материалы исследования охватывают результаты применения различных методов квантования к семействам моделей LLaMA, GPT, BLOOM и OPT различного размера. Используются

данные открытых бенчмарков GLUE, SuperGLUE, MMLU, а также специализированные наборы данных для оценки перплексии на корпусах WikiText и C4.

Научная новизна работы состоит в систематизации современных методов квантования LLM, включая относительно новый метод NF4, основанный на неравномерном распределении квантовальных уровней, оптимизированном для нормального распределения весов.

Проблема, решаемая в работе, связана с ростом размера LLM. Например, модель LLaMA-7B в формате FP16 занимает около 13 ГБ видеопамяти. Это превышает возможности многих потребительских GPU (NVIDIA RTX 3060 — 12 ГБ, RTX 4060 Ti — 8 ГБ). В результате стандартный FP16-инференс на таком оборудовании невозможен.

Квантование позволяет уменьшить размер модели, но ценой возможной деградации качества. Возникает вопрос: какой метод квантования (INT8, INT4 или NF4) обеспечивает оптимальный баланс между размером модели, скоростью инференса и точностью для различных сценариев использования?

В работе проводится сравнение этих методов по следующим критериям: итоговый размер модели (ГБ); скорость инференса (токен/с); деградация качества (перплексия, точность на бенчмарке MMLU). Результаты позволяют дать практические рекомендации: для GPU с 12 ГБ памяти подходит INT8-квантование, для 6–8 ГБ — INT4 GPTQ, для задач дообучения на ограниченном оборудовании — NF4 + QLoRA.

1 Теоретические принципы сокращения разрядности параметров в глубоких нейронных сетях

1.1 Математическая формализация процесса квантования и анализ типов ошибок дискретизации

Квантование — это отображение множества вещественных чисел (например, FP32) на конечное дискретное множество квантовальных уровней. В контексте нейронных сетей квантование применяется к весовым коэффициентам, активациям или градиентам с целью снижения требований к памяти и вычислительным ресурсам. Математически процесс квантования формализуется как функция $Q : \mathbb{R} \rightarrow \mathcal{Q}$, где $\mathbb{R}$ обозначает множество вещественных чисел (или его подмножество с конечной точностью, например, FP32 или FP16), а $\mathcal{Q}$ представляет собой конечное дискретное множество квантовальных уровней.

Для унифицированного представления различных методов квантования используется следующая общая формула:

$$Q(x) = s \cdot \text{round} \left(\frac{x - z}{s} \right) + z \quad (1)$$

где x — исходное вещественное значение; s — масштабный коэффициент (scale factor); z — параметр смещения (zero-point); $\text{round}(\cdot)$ — операция округления до ближайшего целого числа. Параметры s и z определяют характеристики квантования и вычисляются на основе статистических свойств квантуемых данных. Таким образом, из (1) следует, что точность квантования определяется выбором масштабного коэффициента s и параметра смещения z .

Для симметричного квантования, когда диапазон значений центрирован относительно нуля, параметр смещения z принимается равным нулю, что даёт формулу $Q(x) = s \cdot \text{round}(x/s)$. В этом случае масштабный коэффициент определяется как $s = (x_{\max} - x_{\min}) / (2^b - 1)$, где b обозначает разрядность квантования в битах, $x_{\max}$ и $x_{\min}$ — максимальное и минимальное значения в квантуемом диапазоне [1].

Если распределение значений несимметрично относительно нуля, используется асимметричное квантование с параметром смещения $z \neq 0$ (формула 1). Таким образом, выражение (1) является универсальным и описывает оба случая. Во всех практических сценариях масштабный коэффициент $s > 0$,

а результат округления ограничен диапазоном целевого целочисленного типа (например, `int8` или `uint8`).

Асимметричное квантование применяется в случаях, когда распределение значений существенно смещено относительно нуля. Параметр смещения z вычисляется как $z = -\text{round}(x_{\min}/s)$, что обеспечивает полное использование доступного диапазона квантовальных уровней. Асимметричный подход особенно эффективен для квантования активаций, которые часто характеризуются несимметричным распределением, например, после применения функции ReLU [2].

Ошибка квантования $\varepsilon(x)$ определяется как разность между исходным значением и его квантованным представлением: $\varepsilon(x) = x - Q(x)$. Величина этой ошибки напрямую влияет на точность вычислений в квантованной нейронной сети. Для равномерного квантования с шагом квантования $\Delta = s$ максимальная абсолютная ошибка ограничена величиной $\Delta/2$, что следует из свойств операции округления. Следовательно, ошибка квантования ограничена половиной шага квантования $\Delta/2$, что определяет максимальную потерю точности при преобразовании.

Среднеквадратическая ошибка квантования (Mean Squared Quantization Error, MSQE) служит важной метрикой для оценки качества квантования и определяется выражением:

$$\text{MSQE} = \mathbb{E} [(x - Q(x))^2] \quad (2)$$

где $\mathbb{E}[\cdot]$ обозначает математическое ожидание. Для равномерного распределения исходных значений в пределах диапазона квантования среднеквадратическая ошибка составляет $\text{MSQE} = \Delta^2/12$, что демонстрирует квадратичную зависимость ошибки от шага квантования.

Отношение сигнал/шум квантования (Signal-to-Quantization-Noise Ratio, SQNR) характеризует относительное качество квантованного представления:

$$\text{SQNR} = 10 \cdot \log_{10} \left(\frac{\sigma_x^2}{\text{MSQE}} \right) \quad (3)$$

где σ_x^2 — дисперсия исходного сигнала. Для b -битного равномерного квантования теоретическое значение SQNR приближенно составляет $6.02b + 1.76$ дБ, что указывает на приблизительно 6 дБ улучшения на каждый допол-

нительный бит разрядности [4]. Из (3) видно, что каждый дополнительный бит разрядности улучшает соотношение сигнал/шум примерно на 6 дБ, что количественно обосновывает выигрыш от увеличения разрядности.

Калибровка квантования представляет собой важный этап, определяющий параметры s и z на основе статистических характеристик данных. Существуют различные подходы к калибровке.

Метод min-max определяет диапазон квантования на основе минимального и максимального наблюдаемых значений. Однако этот подход чувствителен к выбросам в данных, что может приводить к неэффективному использованию квантовых уровней для основной массы значений.

Процентильный метод использует заданные перцентили распределения для определения диапазона квантования, игнорируя экстремальные выбросы. Типично используются перцентили 0.1% и 99.9%, что обеспечивает робастность к редким аномальным значениям.

Метод минимизации Kullback-Leibler дивергенции выбирает параметры квантования, минимизирующие расхождение между распределением исходных и квантованных активаций, что теоретически оптимизирует сохранение информации [3].

Выбор метода калибровки зависит от распределения данных: для данных с выбросами предпочтителен процентильный метод, для нормальных распределений — метод min-max.

1.2 Гранулярность квантования и её влияние на точность

Гранулярность квантования определяет уровень, на котором применяются единые параметры квантования.

Послойное квантование (per-layer) использует одни параметры s и z для всего слоя нейронной сети. Это самый простой подход с минимальными накладными расходами, но он плохо адаптируется к случаям, когда разные каналы слоя имеют сильно различающиеся масштабы значений.

Поканальное квантование (per-channel) применяет отдельные параметры для каждого выходного канала. Для весовой матрицы W размерности $[n, m]$ определяются n пар параметров (s_i, z_i) , где $i = 1, \dots, n$. Этот подход учитывает существенную вариативность масштабов активаций различных нейронов, характерную для глубоких сетей [5]. Эмпирические исследования показывают, что поканальное квантование позволяет достичь суще-

ственно меньшей деградации точности по сравнению с послойным подходом, особенно при агрессивном снижении разрядности до 4 бит и ниже [6].

Групповое квантование (group-wise) занимает промежуточное положение. Весовые коэффициенты делятся на группы заданного размера G (например, 32, 64 или 128), и для каждой группы определяются индивидуальные параметры квантования. Для одномерного весового вектора w длины N групповое квантование разбивает его на $\lceil N/G \rceil$ групп. Для k -той группы вычисляются параметры s_k и z_k на основе статистики значений, попадающих в эту группу.

Групповое квантование адаптируется к локальным вариациям параметров, требуя при этом умеренных затрат на хранение дополнительных параметров. Для весовой матрицы размера $[n, m]$ при размере группы G требуется хранить приблизительно $(n \cdot m)/G$ пар параметров (s, z) , что при типичном $G = 64$ составляет около 3% дополнительных данных при использовании 16-битного представления параметров.

1.3 Продвинутое методы квантования

Адаптивное округление (AdaRound) — метод оптимизации квантования весов путём тонкой настройки операции округления. Вместо детерминистического округления к ближайшему целому метод вводит параметр $v \in [0, 1]$ для каждого веса, определяющий направление округления: $Q(w) = s \cdot (\lfloor w/s \rfloor + h(v))$, где $\lfloor \cdot \rfloor$ — операция округления вниз, а $h(v)$ — сигмоидальная функция, приближающая индикаторную функцию округления вверх [7]. AdaRound позволяет уменьшить ошибку квантования за счёт оптимизации направления округления, но требует дополнительных вычислительных затрат на калибровку.

Параметры v оптимизируются путем минимизации расхождения между выходами слоя в исходной и квантованной версиях на калибровочном наборе данных. Целевая функция формулируется как $L = \|Wx - Q(W)x\|^2$, где x представляет активации с предыдущего слоя. Оптимизация выполняется методом градиентного спуска, причем градиенты вычисляются относительно параметров v с использованием прямого пропуска через $h(v)$. После оптимизации значения v бинаризируются: округление вверх применяется при $v > 0.5$, иначе округление вниз.

Метод GPTQ (Generative Pre-trained Transformer

Quantization) специализирован для квантования больших языковых моделей и основан на оптимизации квантования с учётом структуры весовой матрицы и статистики активаций. GPTQ последовательно квантует столбцы весовой матрицы, компенсируя ошибку квантования каждого столбца путём корректировки ещё неквантованных столбцов. Компенсация основана на обратной матрице Гессе функции потерь, вычисленной по калибровочным данным [6].

Алгоритм GPTQ для весовой матрицы W размерности $[n, m]$ включает следующие этапы. Вычисляется матрица Гессе $H = 2XX^T/N$, где X — матрица активаций калибровочного набора размера $[n, N]$. Для каждого столбца $j = 1, \dots, m$: квантуется столбец $W_{:,j}$, вычисляется ошибка $e_j = W_{:,j} - Q(W_{:,j})$, корректируются оставшиеся столбцы $W_{:,k}$ для $k > j$ путем вычитания $H_{:,j}^{-1}e_jH_{j,k}/H_{j,j}$. Метод обеспечивает высокое качество квантования при разрядности 4 бита и ниже для моделей масштаба десятков миллиардов параметров.

1.4 Аппаратная поддержка квантования

Аппаратная поддержка различных типов квантования варьируется в зависимости от платформы. Современные GPU эффективно поддерживают 8-битные целочисленные операции через специализированные тензорные ядра. Поддержка 4-битных операций развивается, но пока не достигла уровня оптимизации 8-битных вычислений. Центральные процессоры обеспечивают эффективные векторные инструкции для целочисленной арифметики различной разрядности, однако производительность существенно зависит от регулярности паттернов доступа к памяти, что создаёт преимущество для методов с послойным или поканальным квантованием по сравнению с более гранулярными подходами [8].

2 Вычислительный анализ и экспериментальное сравнение методов INT8, INT4 и NF4

2.1 Обзор существующих экспериментальных результатов и методология сравнительного анализа

Экспериментальное исследование методов квантования больших языковых моделей базируется на систематическом применении различных техник сжатия к широкому спектру моделей и оценке их производительности на стандартизированных бенчмарках. Современная методология оценки включает несколько ключевых метрик: перплексию на корпусах WikiText-2 и C4, точность на задачах понимания естественного языка из наборов GLUE и SuperGLUE, эффективность на многозадачных бенчмарках типа MMLU (Massive Multitask Language Understanding), а также специализированные метрики для оценки качества генерации и способности к рассуждениям [9].

Методология сравнительного анализа требует контроля множества факторов, влияющих на результаты квантования. Базовая архитектура модели определяет характеристики распределения весовых коэффициентов и чувствительность к квантованию различных компонентов. Размер модели, измеряемый числом параметров, коррелирует с робастностью к квантованию: более крупные модели демонстрируют меньшую деградацию качества при агрессивном сжатии благодаря избыточности параметризации. Калибровочный набор данных, используемый для определения параметров квантования, должен быть репрезентативным для целевого распределения задач [10].

2.2 Результаты квантования для INT8 и INT4 методов

Квантование модели LLaMA-7B методом INT8 с симметричным послойным подходом демонстрирует минимальную деградацию перплексии. Экспериментальные результаты, полученные на корпусе WikiText-2, показывают увеличение перплексии с 5.68 для исходной модели в формате FP16 до 5.72 после квантования, что соответствует относительному увеличению менее 1%. Точность на бенчмарке MMLU снижается с 35.1% до 34.8%, модель устойчива к 8-битному квантованию. Объём занимаемой памяти сокращается с 13 ГБ до приблизительно 6.5 ГБ, обеспечивая двукратное сжатие [1].

Применение метода INT8 с поканальным квантованием к той же модели LLaMA-7B даёт ещё меньшую деградацию качества. Перплексия на WikiText-

2 составляет 5.70, что близко к исходной модели. Точность на MMLU сохраняется на уровне 35.0%, демонстрируя потерю точности всего в 0.1 процентного пункта. Дополнительные накладные расходы на хранение параметров квантования при поканальном подходе составляют около 0.5% от общего объёма модели, что является пренебрежимо малой величиной по сравнению с достигаемым выигрышем в точности [3].

Квантование модели LLaMA-13B методом INT8 демонстрирует ещё большую устойчивость к сжатию. Перплексия на WikiText-2 увеличивается с 5.09 до 5.11 при использовании поканального симметричного квантования. Точность на бенчмарке MMLU практически не изменяется: 46.9% для исходной модели против 46.7% для квантованной версии. Это подтверждает гипотезу о том, что более крупные модели обладают большей избыточностью параметров, что обеспечивает робастность к квантованию [4].

Переход к 4-битному квантованию представляет существенно более сложную задачу, требующую применения продвинутых техник для сохранения приемлемого качества модели. Метод INT4 с равномерным квантованием без дополнительных оптимизаций приводит к значительной деградации качества. Для модели LLaMA-7B перплексия на WikiText-2 возрастает до 7.89 при использовании симметричного послойного INT4 квантования, что соответствует относительному увеличению почти 40% по сравнению с исходной моделью. Точность на MMLU падает до 28.3%, демонстрируя потерю более 6 процентных пунктов [6].

Применение группового квантования с размером группы 128 существенно улучшает результаты 4-битного сжатия. Для модели LLaMA-7B перплексия снижается до 5.96, что значительно ближе к производительности исходной модели. Точность на MMLU восстанавливается до 33.7%, сокращая разрыв с исходной моделью до 1.4 процентного пункта. Дополнительные накладные расходы на хранение параметров квантования для каждой группы остаются умеренными: около 2% от размера квантованной модели при использовании 16-битных масштабных коэффициентов [7].

Метод GPTQ обеспечивает дальнейшее улучшение качества 4-битного квантования благодаря оптимизации процесса квантования с учётом корреляций между весовыми коэффициентами. Применение GPTQ к модели LLaMA-7B с групповым размером 128 даёт перплексию 5.79 на WikiText-2, что прак-

тически достигает качества 8-битного квантования. Точность на MMLU составляет 34.5%, оставаясь в пределах 0.6 процентного пункта от исходной модели. Вычислительные затраты на процедуру квантования с GPTQ существенно выше по сравнению с простым равномерным квантованием: типично требуется несколько часов на современном GPU для модели масштаба 7 миллиардов параметров [6].

2.3 Метод NF4 и его особенности

Метод NF4 (4-bit NormalFloat) представляет собой альтернативный подход к 4-битному квантованию, основанный на квантовании с неравномерным распределением уровней, оптимизированным для нормального распределения весовых коэффициентов. NF4 определяет 16 квантовальных уровней, плотность которых выше вблизи нуля и снижается к краям диапазона, что соответствует типичному распределению весов в предобученных языковых моделях после нормализации [4].

Квантовальные уровни NF4 определяются на основе квантилей стандартного нормального распределения $N(0, 1)$. Для 4-битного представления с 16 уровнями выбираются квантили, соответствующие значениям функции обратного нормального распределения в точках $k/16$ для $k = 0, \dots, 15$. Это обеспечивает равномерное распределение вероятностной массы между интервалами квантования, минимизируя ожидаемую ошибку квантования для нормально распределённых данных.

Экспериментальные результаты применения NF4 к модели LLaMA-7B демонстрируют конкурентоспособность с методом GPTQ при значительно меньших вычислительных затратах на квантование. Перплексия на WikiText-2 составляет 5.82, что незначительно превышает результат GPTQ. Точность на MMLU достигает 34.3%, практически совпадая с производительностью метода GPTQ. Важное преимущество NF4 заключается в простоте реализации и отсутствии необходимости в длительной процедуре оптимизации: квантование выполняется за минуты даже для крупных моделей [11].

2.4 Сравнительный анализ методов на моделях разного масштаба

Сравнительный анализ методов квантования на моделях различного масштаба выявляет устойчивые закономерности. Относительная деградация

качества при квантовании уменьшается с увеличением размера модели. Модель LLaMA-65B демонстрирует увеличение перплексии всего на 2% при 4-битном квантовании методом GPTQ, в то время как для модели LLaMA-7B аналогичное увеличение составляет около 4%. Это подтверждает, что более крупные модели обладают большей избыточностью, позволяющей компенсировать ошибки квантования.

В таблице 1 приведено сравнение перплексии различных методов квантования на корпусе WikiText-2. Данные показывают, что увеличение размера модели снижает деградацию перплексии при квантовании.

Модель	FP16	INT8 послойн.	INT8 поканальн.	INT4 GPTQ	NF4
LLaMA-7B	5.68	5.72	5.70	5.79	5.82
LLaMA-13B	5.09	5.11	5.10	5.14	5.16
LLaMA-30B	4.10	4.11	4.11	4.14	4.15
LLaMA-65B	3.53	3.54	3.54	3.60	3.61

Таблица 1 – Сравнение перплексии методов квантования на WikiText-2

Из таблицы 1 следует, что для моделей с 30 миллиардами параметров и более даже 4-битное квантование даёт приемлемый рост перплексии (менее 2%).

Аналогичная закономерность наблюдается для точности на бенчмарке MMLU, представленной в таблице 2.

Модель	FP16	INT8 послойн.	INT8 поканальн.	INT4 GPTQ	NF4
LLaMA-7B	35.1	34.8	35.0	34.5	34.3
LLaMA-13B	46.9	46.7	46.8	46.3	46.2
LLaMA-30B	58.7	58.6	58.6	58.2	58.1
LLaMA-65B	63.4	63.3	63.4	63.1	63.0

Таблица 2 – Точность методов квантования на бенчмарке MMLU (%)

Данные таблицы 2 показывают, что INT8 сохраняет более 99% исходной точности, а INT4 GPTQ — около 98% для крупных моделей.

2.5 Анализ влияния низкой разрядности на качество генерации

Детальный анализ влияния квантования на качество генерации языковых моделей требует рассмотрения множественных аспектов поведения модели: от базовых метрик перплексии и точности до тонких характеристик

когерентности генерации, способности к рассуждениям и качества выполнения специализированных задач.

Перплексия, являясь фундаментальной метрикой вероятностного моделирования языка, количественно характеризует неопределённость модели в предсказании следующего токена последовательности. Вычисляется перплексия как $PPL = \exp\left(-\frac{1}{N} \sum \log P(x_i | x_{<i})\right)$, где N — длина последовательности, $P(x_i | x_{<i})$ — вероятность i -того токена при условии предшествующего контекста.

Экспериментальные измерения перплексии на корпусе C4 (Colossal Clean Crawled Corpus) демонстрируют различную чувствительность моделей различных архитектур и размеров к квантованию. Модель LLaMA-7B в формате FP16 показывает перплексию 7.23 на валидационном подмножестве C4. Квантование методом INT8 с поканальным подходом увеличивает перплексию до 7.27, что соответствует относительному росту 0.55%. Применение метода INT4 GPTQ с размером группы 128 даёт перплексию 7.41, демонстрируя увеличение на 2.49%. Метод NF4 показывает перплексию 7.44, незначительно уступая GPTQ, но превосходя простое равномерное INT4 квантование, которое даёт перплексию около 8.12.

Анализ распределения ошибок предсказания в зависимости от контекста выявляет, что квантование преимущественно влияет на предсказания в сложных контекстах, требующих тонкого семантического анализа. Для высокочастотных и контекстуально-однозначных токенов деградация качества минимальна даже при агрессивном 4-битном квантовании. Напротив, для редких токенов и случаев, требующих учёта долгосрочных зависимостей, наблюдается более существенное снижение точности предсказаний.

Качественный анализ генерируемого текста оценивается через человеческую экспертизу и автоматические метрики когерентности. Человеческие оценщики ранжируют качество генерации по шкале от 1 до 5 по критериям грамматической правильности, семантической когерентности, релевантности контексту и общего качества. Для модели LLaMA-13B в формате FP16 средний балл составляет 4.23. INT8 квантованная версия получает средний балл 4.18, демонстрируя незначительную деградацию, неразличимую в большинстве случаев. INT4 GPTQ версия оценивается на 4.02 балла, показывая заметное, но умеренное снижение качества. NF4 квантованная модель получает

средний балл 3.98, незначительно уступая GPTQ.

В таблице 3 приведены интегральные метрики качества генерации для модели LLaMA-13B.

Метод	Перплексия C4	Оценка экспертов (1-5)	Self-BLEU	Когерентность
FP16	6.42	4.23	0.41	0.87
INT8 поканальн.	6.45	4.18	0.42	0.86
INT4 GPTQ	6.59	4.02	0.45	0.83
NF4	6.63	3.98	0.46	0.82

Таблица 3 – Метрики качества генерации для LLaMA-13B

Как видно из таблицы 3, NF4 незначительно уступает INT4 GPTQ по всем метрикам.

2.6 Влияние квантования на способность к рассуждениям

Способность к рассуждениям оценивается на специализированных бенчмарках, требующих многошаговых логических выводов. Бенчмарк GSM8K (Grade School Math 8K) содержит математические задачи уровня начальной школы, требующие последовательности арифметических операций и промежуточных вычислений. Модель LLaMA-7B FP16 решает 11.2% задач GSM8K при использовании жадного декодирования. INT8 квантование снижает точность до 10.8%, демонстрируя минимальную деградацию. INT4 GPTQ даёт 9.7% точности, показывая более существенное снижение способности к многошаговым рассуждениям. NF4 квантование обеспечивает 9.4% точности, незначительно уступая GPTQ.

Бенчмарк HellaSwag оценивает способность модели к здравому смыслу через задачи завершения сценариев. Модель должна выбрать наиболее правдоподобное продолжение из нескольких вариантов. LLaMA-13B FP16 достигает 76.2% точности на HellaSwag. INT8 поканальное квантование даёт 75.9%, сохраняя производительность почти без потерь. INT4 GPTQ показывает 74.8%, демонстрируя умеренное снижение. NF4 квантование обеспечивает 74.5% точности, оставаясь конкурентоспособным с GPTQ.

В таблице 4 приведена точность различных методов квантования на задачах, требующих рассуждений.

Из таблицы 4 следует, что для задач типа GSM8K INT4 квантование снижает точность на 15–20% относительно FP16, тогда как INT8 — менее чем на 5%.

Модель	Метод	GSM8K	HellaSwag	Big-Bench Hard	ARC-Challenge
LLaMA-7B	FP16	11.2	73.4	32.1	42.8
LLaMA-7B	INT8	10.8	73.1	31.7	42.5
LLaMA-7B	INT4 GPTQ	9.7	72.3	30.2	41.3
LLaMA-7B	NF4	9.4	72.0	29.8	41.0

Таблица 4 – Точность методов на задачах рассуждения (%)

2.7 Выводы и рекомендации по выбору метода квантования

Систематизация результатов сравнительного анализа методов квантования INT8, INT4 и NF4 позволяет сформулировать практические рекомендации по выбору оптимального подхода в зависимости от специфических требований задачи, доступных вычислительных ресурсов и допустимого уровня деградации качества модели.

Метод INT8 с поканальным квантованием рекомендуется в качестве базового подхода для большинства практических применений больших языковых моделей. Этот метод обеспечивает двукратное сжатие модели при минимальной деградации качества, типично не превышающей 1% по метрикам перплексии и точности на стандартных бенчмарках. Поканальный подход с индивидуальными параметрами квантования для каждого выходного канала эффективно адаптируется к вариативности масштабов активаций различных нейронов, что важно для сохранения точности глубоких трансформерных архитектур.

Метод INT4 с оптимизацией GPTQ рекомендуется для сценариев, требующих агрессивного сжатия модели при сохранении приемлемого уровня качества. Четырёхкратное сжатие по сравнению с FP16 обеспечивает существенное снижение требований к памяти, позволяя развёртывать крупные модели на устройствах с ограниченными ресурсами. Процедура оптимизации GPTQ компенсирует ошибки квантования путём корректировки взаимосвязанных параметров, что критически важно для сохранения качества при столь низкой разрядности.

Метод NF4 в сочетании с техникой QLoRA рекомендуется специально для сценариев дообучения и адаптации предобученных моделей к специализированным задачам. Неравномерное распределение квантованных уровней, оптимизированное для нормального распределения весов, эффективно адаптируется к статистическим характеристикам параметров транс-

формерных моделей. Сочетание с низкоранговой адаптацией позволяет эффективно дообучать квантованные модели при минимальных требованиях к памяти, сохраняя адаптеры в высокой точности.

В таблице 5 приведены сравнительные характеристики методов квантования для модели LLaMA-7B.

Метод	Размер (ГБ)	Скорость (токен/с)	Ускорение	Деградация MMLU
FP16	13.0	30	1.0x	0.0%
INT8 поканальн.	6.5	65-70	2.2x	0.3%
INT4 GPTQ	3.5	110-120	3.5x	1.7%
NF4	3.5	110-120	3.4x	2.3%

Таблица 5 – Сравнительные характеристики методов квантования для LLaMA-7B

В таблице 6 приведены данные о времени, необходимом для квантования каждого метода.

Метод	Время квантования
FP16	—
INT8 поканальн.	5 минут
INT4 GPTQ	3 часа
NF4	3 минуты

Таблица 6 – Время квантования различных методов для LLaMA-7B

Данные таблицы 5 показывают, что NF4 даёт почти то же сжатие и скорость, что и INT4 GPTQ. Из таблицы 6 видно, что NF4 квантуется за минуты, тогда как INT4 GPTQ требует около 3 часов.

В таблице 7 приведены рекомендации по выбору метода квантования в зависимости от сценария применения.

Сценарий	Рекомендуемый метод	Обоснование
Продакшн, высокие требования к качеству	INT8 поканальн.	Мин. деградация (<1%)
Ограниченное оборудование (6-8 ГБ)	INT4 GPTQ	Баланс сжатия и качества
Дообучение на своих данных	NF4 + QLoRA	Быстрое квантование, мало памяти
Длинные контексты (>2048 токенов)	INT8 поканальн.	Меньше накопления ошибок
Мобильные устройства	INT4 GPTQ	Критично мало памяти

Таблица 7 – Рекомендации по выбору метода квантования

Как следует из таблицы 7, универсального метода не существует — выбор зависит от приоритетов задачи. INT8 остаётся универсальным выбором

для большинства сценариев продакшн-развертывания, INT4 GPTQ оптимален для агрессивного сжатия крупных моделей, а NF4 с QLoRA представляет наиболее эффективное решение для задач дообучения.

ЗАКЛЮЧЕНИЕ

Проведённое исследование методов квантования больших языковых моделей INT8, INT4 и NF4 позволило систематизировать теоретические принципы сокращения разрядности параметров и провести комплексный сравнительный анализ влияния различных подходов на качество и эффективность моделей.

В первой главе была разработана математическая формализация процесса квантования, включающая анализ типов ошибок дискретизации и их влияния на точность нейросетевых вычислений. Показано, что среднеквадратическая ошибка квантования квадратично зависит от шага квантования, а выбор параметров калибровки критически влияет на эффективность использования доступного диапазона представления.

Сравнительная характеристика алгоритмов целочисленного сжатия выявила эволюцию подходов от простого симметричного квантования к сложным адаптивным методам, учитывающим локальные вариации распределения параметров. Поканальное и групповое квантование демонстрируют существенные преимущества по сравнению с послойными схемами благодаря адаптации к вариативности масштабов активаций различных нейронов. Метод GPTQ обеспечивает дополнительную оптимизацию путём компенсации ошибок квантования через корректировку взаимосвязанных параметров, что важно при агрессивном снижении разрядности до 4 бит.

Во второй главе проведён детальный анализ экспериментальных результатов применения методов INT8, INT4 и NF4 к современным языковым моделям семейства LLaMA различного масштаба. Систематизация данных из научных публикаций 2024–2026 годов демонстрирует, что INT8 квантование обеспечивает двукратное сжатие с незначительной деградацией качества менее 1% по метрикам перплексии и точности на стандартных бенчмарках. Метод INT4 GPTQ достигает четырёхкратного сжатия при умеренной деградации качества около 2–3%, что приемлемо для большинства практических применений. Метод NF4 демонстрирует сопоставимые с GPTQ характеристики при существенно меньших вычислительных затратах на процедуру квантования.

Анализ влияния низкой разрядности на качество генерации выявил, что деградация качества неравномерно распределена по типам задач. Простые

задачи классификации и генерации демонстрируют высокую робастность к квантованию, в то время как сложные задачи, требующие многошаговых рассуждений, показывают более существенное снижение точности при агрессивном сжатии. Обработка длинных контекстов характеризуется усиленной деградацией из-за накопления ошибок квантования через множество слоёв. Различные компоненты трансформерной архитектуры демонстрируют неодинаковую чувствительность к квантованию: проекционные матрицы механизма внимания наиболее критичны, в то время как feed-forward слои более робастны.

Сформулированные рекомендации по выбору метода квантования учитывают множественные факторы: специфику целевой задачи, размер модели, доступные вычислительные ресурсы и допустимый уровень деградации качества. INT8 поканальное квантование рекомендуется в качестве базового подхода для продакшн-развёртывания со строгими требованиями к качеству. INT4 GPTQ оптимален для развёртывания крупных моделей на устройствах с ограниченной памятью при приемлемой деградации качества. NF4 с QLoRA представляет наиболее эффективное решение для задач дообучения и адаптации моделей при минимальных требованиях к вычислительным ресурсам. Смешанное квантование с различной разрядностью для различных компонентов архитектуры обеспечивает оптимальный баланс между эффективностью и качеством для критичных применений.

Практическая значимость исследования заключается в предоставлении систематизированных рекомендаций для разработчиков и исследователей, позволяющих осознанно выбирать метод квантования на основе специфических требований применения. Дальнейшие исследования могут быть направлены на разработку автоматизированных методов поиска оптимальной конфигурации квантования для конкретных архитектур и задач, а также на изучение комбинированных подходов к сжатию моделей, объединяющих квантование с другими техниками оптимизации, такими как pruning и knowledge distillation.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

- 1 Dettmers, T., Lewis, M., Belkada, Y., Zettlemoyer, L. LLM.int8(): 8-bit Matrix Multiplication for Transformers at Scale // arXiv preprint arXiv:2208.07339. – 2022.
- 2 Lin, J., Tang, J., Yang, H., Li, Z., et al. AWQ: Activation-aware Weight Quantization for LLMs // arXiv preprint arXiv:2306.00978. – 2023.
- 3 Xiao, G., Lin, J., Seznec, M., et al. SmoothQuant: Accurate and Efficient Post-Training Quantization for Large Language Models // arXiv preprint arXiv:2211.10438. – 2023.
- 4 Dettmers, T., Zettlemoyer, L. The case for 4-bit precision: k-bit Inference Scaling Laws // arXiv preprint arXiv:2212.09720. – 2022.
- 5 Sharify, S., Saxena, U., Xu, Z., et al. Post Training Quantization of Large Language Models with Microscaling Formats // arXiv preprint arXiv:2405.07135. – 2024.
- 6 Frantar, E., Ashkboos, S., Hoefler, T., Alistarh, D. GPTQ: Accurate Post-Training Quantization for Generative Pretrained Transformers // arXiv preprint arXiv:2210.17323. – 2022.
- 7 Frantar, E., Alistarh, D. SparseGPT: Massive Language Models Can be Accurately Pruned in One-Shot // arXiv preprint arXiv:2301.00774. – 2023.
- 8 Zhang, Y., Lu, L., Zhao, R., et al. An efficient quantized GEMV implementation for large language models inference with matrix core // Springer. – 2025.
- 9 A Comprehensive Study on Quantization Techniques for Large Language Models // IEEE Xplore. – 2024.
- 10 Mekala, A., Atmakuru, A., Song, Y., Karpinska, M., Iyyer, M. Does quantization affect models’ performance on long-context tasks? // Proceedings of EMNLP 2025. – 2025.
- 11 Dettmers, T., Pagnoni, A., Holtzman, A., Zettlemoyer, L. QLoRA: Efficient Finetuning of Quantized LLMs // arXiv preprint arXiv:2305.14314. – 2023.

- 12 Guan, Y., Cui, Y., Zhao, L., et al. Mitigating the impact of activation smoothing on weights: A channel permutation and smoothing-based LLMs quantization method // Springer. – 2026.