

МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение
высшего образования

**«САРАТОВСКИЙ НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ
ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ИМЕНИ Н. Г. ЧЕРНЫШЕВСКОГО»**

Кафедра дискретной математики и информационных технологий

**СРАВНЕНИЕ МЕТОДОВ КВАНТОВАНИЯ LLM (INT8, INT4,
NF4)**

КУРСОВАЯ РАБОТА

студента 2 курса 221 группы
направления 09.03.01 – Информатика и вычислительная техника
факультета КНиИТ
Соколов Даниил Васильевич

Научный руководитель

ст. преподаватель

П. О. Дмитриев

Заведующий кафедрой

к. ф.-м. н., доцент

Л. Б. Тяпаев

Саратов 2026

СОДЕРЖАНИЕ

ОБОЗНАЧЕНИЯ И СОКРАЩЕНИЯ	3
ВВЕДЕНИЕ	4
1 Теоретические принципы сокращения разрядности параметров в глубоких нейронных сетях.....	5
1.1 Математическая формализация процесса квантования и анализ типов ошибок дискретизации	5
1.2 Гранулярность квантования и её влияние на точность	7
1.3 Продвинутое методы квантования	8
1.4 Аппаратная поддержка квантования	9
2 Вычислительный анализ и экспериментальное сравнение методов INT8, INT4 и NF4.....	10
2.1 Обзор существующих экспериментальных результатов и методология сравнительного анализа	10
2.2 Результаты квантования для INT8 и INT4 методов	10
2.3 Метод NF4 и его особенности	12
2.4 Сравнительный анализ методов на моделях разного масштаба ...	12
2.5 Анализ влияния низкой разрядности на качество генерации	13
2.6 Влияние квантования на способность к рассуждениям	15
2.7 Выводы и рекомендации по выбору метода квантования	16
ЗАКЛЮЧЕНИЕ	19
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ.....	21

ОБОЗНАЧЕНИЯ И СОКРАЩЕНИЯ

LLM Large Language Models, большие языковые модели

INT8 8-битное целочисленное квантование

INT4 4-битное целочисленное квантование

NF4 4-bit NormalFloat, квантование с нормальным распределением уровней

GPTQ Generative Pre-trained Transformer Quantization

QLoRA Quantized Low-Rank Adaption

MMLU Massive Multitask Language Understanding

MSQE Mean Squared Quantization Error, среднеквадратическая ошибка квантования

FP16 16-битное число с плавающей точкой

SQNR Signal-to-Quantization-Noise Ratio

ВВЕДЕНИЕ

Большие языковые модели с каждым годом становятся всё больше. Модели вроде GPT-4, LLaMA или Gemini содержат десятки и сотни миллиардов параметров. С одной стороны, это даёт им возможность решать сложные задачи: писать тексты, отвечать на вопросы, переводить языки. С другой стороны, такие модели требуют огромного количества видеопамяти. Например, модель LLaMA с 7 миллиардами параметров в стандартном 16-битном формате занимает около 13 гигабайт. Это больше, чем есть на многих домашних видеокартах, таких как RTX 3060 с 12 ГБ или RTX 4060 Ti с 8 ГБ. Получается, что обычный пользователь не может запустить такую модель на своём компьютере.

Здесь на помощь приходит квантование. Квантование это процесс сжатия модели: вместо того чтобы хранить числа в высокоточном 16-битном формате, их переводят в менее точные форматы, например 8-битный целочисленный или 4-битный. Это сильно уменьшает размер модели, но может немного ухудшить качество её работы. Задача разработчика найти баланс: сжать модель настолько, чтобы она влезала в память, но при этом не слишком сильно теряла в точности.

В последние годы появилось несколько разных методов квантования. Самые популярные из них классическое 8-битное квантование, которое почти не портит качество; 4-битное квантование GPTQ, дающее хорошее сжатие, но требующее часов на подготовку; и 4-битное квантование NF4 с неравномерной сеткой уровней, разработанное специально для нормального распределения весов в LLM. Цель этой работы разобраться, чем отличаются эти методы, как они работают, и дать практические рекомендации: какой метод выбирать в разных ситуациях.

Для этого в работе решаются следующие задачи. Во-первых, исследуются математические принципы сокращения разрядности параметров в нейронных сетях. Во-вторых, проводится сравнительный анализ алгоритмов квантования от простого симметричного до сложного GPTQ. В-третьих, на основе данных из научных статей 2022-2026 годов систематизируются экспериментальные результаты применения методов INT8, INT4 и NF4. И в-четвёртых, формулируются практические рекомендации по выбору метода в зависимости от доступных ресурсов и требований к качеству.

1 Теоретические принципы сокращения разрядности параметров в глубоких нейронных сетях

1.1 Математическая формализация процесса квантования и анализ типов ошибок дискретизации

Квантование это отображение множества вещественных чисел (например, FP32) на конечное дискретное множество квантовальных уровней. В контексте нейронных сетей квантование применяется к весовым коэффициентам, активациям или градиентам с целью снижения требований к памяти и вычислительным ресурсам. Математически процесс квантования формализуется как функция $Q : \mathbb{R} \rightarrow \mathcal{Q}$, где $\mathbb{R}$ обозначает множество вещественных чисел (или его подмножество с конечной точностью, например, FP32 или FP16), а $\mathcal{Q}$ представляет собой конечное дискретное множество квантовальных уровней.

Для унифицированного представления различных методов квантования используется следующая общая формула:

$$Q(x) = s \cdot \text{round} \left(\frac{x - z}{s} \right) + z \quad (1)$$

где x исходное вещественное значение; s масштабный коэффициент (scale factor); z параметр смещения (zero-point); $\text{round}(\cdot)$ операция округления до ближайшего целого числа. Параметры s и z определяют характеристики квантования и вычисляются на основе статистических свойств квантуемых данных. Таким образом, из (1) следует, что точность квантования определяется выбором масштабного коэффициента s и параметра смещения z .

Для симметричного квантования, когда диапазон значений центрирован относительно нуля, параметр смещения z принимается равным нулю, что даёт формулу $Q(x) = s \cdot \text{round}(x/s)$. В этом случае масштабный коэффициент определяется как $s = (x_{\max} - x_{\min}) / (2^b - 1)$, где b обозначает разрядность квантования в битах, $x_{\max}$ и $x_{\min}$ максимальное и минимальное значения в квантуемом диапазоне [1].

Если распределение значений несимметрично относительно нуля, используется асимметричное квантование с параметром смещения $z \neq 0$ (формула 1). Таким образом, выражение (1) является универсальным и описывает оба случая. Во всех практических сценариях масштабный коэффициент $s > 0$,

а результат округления ограничен диапазоном целевого целочисленного типа (например, `int8` или `uint8`).

Асимметричное квантование применяется в случаях, когда распределение значений существенно смещено относительно нуля. Параметр смещения z вычисляется как $z = -\text{round}(x_{\min}/s)$, что обеспечивает полное использование доступного диапазона квантовальных уровней. Асимметричный подход особенно эффективен для квантования активаций, которые часто характеризуются несимметричным распределением, например, после применения функции ReLU [2].

Ошибка квантования $\varepsilon(x)$ определяется как разность между исходным значением и его квантованным представлением: $\varepsilon(x) = x - Q(x)$. Величина этой ошибки напрямую влияет на точность вычислений в квантованной нейронной сети. Для равномерного квантования с шагом квантования $\Delta = s$ максимальная абсолютная ошибка ограничена величиной $\Delta/2$, что следует из свойств операции округления. Следовательно, ошибка квантования ограничена половиной шага квантования $\Delta/2$, что определяет максимальную потерю точности при преобразовании.

Среднеквадратическая ошибка квантования (Mean Squared Quantization Error, MSQE) служит важной метрикой для оценки качества квантования и определяется выражением:

$$\text{MSQE} = \mathbb{E} [(x - Q(x))^2] \quad (2)$$

где $\mathbb{E}[\cdot]$ обозначает математическое ожидание. Для равномерного распределения исходных значений в пределах диапазона квантования среднеквадратическая ошибка составляет $\text{MSQE} = \Delta^2/12$, что демонстрирует квадратичную зависимость ошибки от шага квантования.

Отношение сигнал/шум квантования (Signal-to-Quantization-Noise Ratio, SQNR) характеризует относительное качество квантованного представления:

$$\text{SQNR} = 10 \cdot \log_{10} \left(\frac{\sigma_x^2}{\text{MSQE}} \right) \quad (3)$$

где σ_x^2 дисперсия исходного сигнала. Для b -битного равномерного квантования теоретическое значение SQNR приближенно составляет $6.02b + 1.76$ дБ, что указывает на приблизительно 6 дБ улучшения на каждый дополнительный

ный бит разрядности [4]. Из (3) видно, что каждый дополнительный бит разрядности улучшает соотношение сигнал/шум примерно на 6 дБ, что количественно обосновывает выигрыш от увеличения разрядности.

Калибровка квантования представляет собой важный этап, определяющий параметры s и z на основе статистических характеристик данных. Существуют различные подходы к калибровке.

Метод min-max определяет диапазон квантования на основе минимального и максимального наблюдаемых значений. Однако этот подход чувствителен к выбросам в данных, что может приводить к неэффективному использованию квантованных уровней для основной массы значений.

Процентильный метод использует заданные перцентили распределения для определения диапазона квантования, игнорируя экстремальные выбросы. Типично используются перцентили 0.1% и 99.9%, что обеспечивает робастность к редким аномальным значениям.

Метод минимизации Kullback-Leibler дивергенции выбирает параметры квантования, минимизирующие расхождение между распределением исходных и квантованных активаций, что теоретически оптимизирует сохранение информации [3].

Выбор метода калибровки зависит от распределения данных: для данных с выбросами предпочтителен процентильный метод, для нормальных распределений метод min-max.

1.2 Гранулярность квантования и её влияние на точность

Гранулярность квантования определяет уровень, на котором применяются единые параметры квантования.

Послойное квантование (per-layer) использует одни параметры s и z для всего слоя нейронной сети. Это самый простой подход с минимальными накладными расходами, но он плохо адаптируется к случаям, когда разные каналы слоя имеют сильно различающиеся масштабы значений.

Поканальное квантование (per-channel) применяет отдельные параметры для каждого выходного канала. Для весовой матрицы W размерности $[n, m]$ определяются n пар параметров (s_i, z_i) , где $i = 1, \dots, n$. Этот подход учитывает существенную вариативность масштабов активаций различных нейронов, характерную для глубоких сетей [5]. Эмпирические исследования показывают, что поканальное квантование позволяет достичь суще-

ственно меньшей деградации точности по сравнению с послойным подходом, особенно при агрессивном снижении разрядности до 4 бит и ниже [6].

Групповое квантование (group-wise) занимает промежуточное положение. Весовые коэффициенты делятся на группы заданного размера G (например, 32, 64 или 128), и для каждой группы определяются индивидуальные параметры квантования. Для одномерного весового вектора w длины N групповое квантование разбивает его на $\lceil N/G \rceil$ групп. Для k -той группы вычисляются параметры s_k и z_k на основе статистики значений, попадающих в эту группу.

Групповое квантование адаптируется к локальным вариациям параметров, требуя при этом умеренных затрат на хранение дополнительных параметров. Для весовой матрицы размера $[n, m]$ при размере группы G требуется хранить приблизительно $(n \cdot m)/G$ пар параметров (s, z) , что при типичном $G = 64$ составляет около 3% дополнительных данных при использовании 16-битного представления параметров.

1.3 Продвинутое методы квантования

Адаптивное округление (AdaRound) метод оптимизации квантования весов путём тонкой настройки операции округления. Вместо детерминистического округления к ближайшему целому метод вводит параметр $v \in [0, 1]$ для каждого веса, определяющий направление округления: $Q(w) = s \cdot (\lfloor w/s \rfloor + h(v))$, где $\lfloor \cdot \rfloor$ операция округления вниз, а $h(v)$ сигмоидальная функция, приближающая индикаторную функцию округления вверх [7]. AdaRound позволяет уменьшить ошибку квантования за счёт оптимизации направления округления, но требует дополнительных вычислительных затрат на калибровку.

Параметры v оптимизируются путем минимизации расхождения между выходами слоя в исходной и квантованной версиях на калибровочном наборе данных. Целевая функция формулируется как $L = \|Wx - Q(W)x\|^2$, где x представляет активации с предыдущего слоя. Оптимизация выполняется методом градиентного спуска, причем градиенты вычисляются относительно параметров v с использованием прямого пропуска через $h(v)$. После оптимизации значения v бинаризируются: округление вверх применяется при $v > 0.5$, иначе округление вниз.

Метод GPTQ (Generative Pre-trained Transformer Quantization) специ-

ализирован для квантования больших языковых моделей и основан на оптимизации квантования с учётом структуры весовой матрицы и статистики активаций. GPTQ последовательно квантует столбцы весовой матрицы, компенсируя ошибку квантования каждого столбца путём корректировки ещё неквантованных столбцов. Компенсация основана на обратной матрице Гессе функции потерь, вычисленной по калибровочным данным [6].

Алгоритм GPTQ для весовой матрицы W размерности $[n, m]$ включает следующие этапы. Вычисляется матрица Гессе $H = 2XX^T/N$, где X матрица активаций калибровочного набора размера $[n, N]$. Для каждого столбца $j = 1, \dots, m$: квантуется столбец $W_{:,j}$, вычисляется ошибка $e_j = W_{:,j} - Q(W_{:,j})$, корректируются оставшиеся столбцы $W_{:,k}$ для $k > j$ путем вычитания $H_{:,j}^{-1} e_j H_{j,k} / H_{j,j}$. Метод обеспечивает высокое качество квантования при разрядности 4 бита и ниже для моделей масштаба десятков миллиардов параметров.

1.4 Аппаратная поддержка квантования

Аппаратная поддержка различных типов квантования варьируется в зависимости от платформы. Современные GPU эффективно поддерживают 8-битные целочисленные операции через специализированные тензорные ядра. Поддержка 4-битных операций развивается, но пока не достигла уровня оптимизации 8-битных вычислений. Центральные процессоры обеспечивают эффективные векторные инструкции для целочисленной арифметики различной разрядности, однако производительность существенно зависит от регулярности паттернов доступа к памяти, что создаёт преимущество для методов с послойным или поканальным квантованием по сравнению с более гранулярными подходами [8].

2 Вычислительный анализ и экспериментальное сравнение методов INT8, INT4 и NF4

2.1 Обзор существующих экспериментальных результатов и методология сравнительного анализа

Экспериментальное исследование методов квантования больших языковых моделей базируется на систематическом применении различных техник сжатия к широкому спектру моделей и оценке их производительности на стандартизированных бенчмарках. Современная методология оценки включает несколько ключевых метрик: перплексию на корпусах WikiText-2 и C4, точность на задачах понимания естественного языка из наборов GLUE и SuperGLUE, эффективность на многозадачных бенчмарках типа MMLU (Massive Multitask Language Understanding), а также специализированные метрики для оценки качества генерации и способности к рассуждениям [9].

Методология сравнительного анализа требует контроля множества факторов, влияющих на результаты квантования. Базовая архитектура модели определяет характеристики распределения весовых коэффициентов и чувствительность к квантованию различных компонентов. Размер модели, измеряемый числом параметров, коррелирует с робастностью к квантованию: более крупные модели демонстрируют меньшую деградацию качества при агрессивном сжатии благодаря избыточности параметризации. Калибровочный набор данных, используемый для определения параметров квантования, должен быть репрезентативным для целевого распределения задач [10].

2.2 Результаты квантования для INT8 и INT4 методов

Квантование модели LLaMA-7B методом INT8 с симметричным послойным подходом демонстрирует минимальную деградацию перплексии. Экспериментальные результаты, полученные на корпусе WikiText-2, показывают увеличение перплексии с 5.68 для исходной модели в формате FP16 до 5.72 после квантования, что соответствует относительному увеличению менее 1%. Точность на бенчмарке MMLU снижается с 35.1% до 34.8%, модель устойчива к 8-битному квантованию. Объём занимаемой памяти сокращается с 13 ГБ до приблизительно 6.5 ГБ, обеспечивая двукратное сжатие [1].

Применение метода INT8 с поканальным квантованием к той же модели LLaMA-7B даёт ещё меньшую деградацию качества. Перплексия на WikiText-

2 составляет 5.70, что близко к исходной модели. Точность на MMLU сохраняется на уровне 35.0%, демонстрируя потерю точности всего в 0.1 процентного пункта. Дополнительные накладные расходы на хранение параметров квантования при поканальном подходе составляют около 0.5% от общего объёма модели, что является пренебрежимо малой величиной по сравнению с достигаемым выигрышем в точности [3].

Квантование модели LLaMA-13B методом INT8 демонстрирует ещё большую устойчивость к сжатию. Перплексия на WikiText-2 увеличивается с 5.09 до 5.11 при использовании поканального симметричного квантования. Точность на бенчмарке MMLU практически не изменяется: 46.9% для исходной модели против 46.7% для квантованной версии. Это подтверждает гипотезу о том, что более крупные модели обладают большей избыточностью параметров, что обеспечивает робастность к квантованию [4].

Переход к 4-битному квантованию представляет существенно более сложную задачу, требующую применения продвинутых техник для сохранения приемлемого качества модели. Метод INT4 с равномерным квантованием без дополнительных оптимизаций приводит к значительной деградации качества. Для модели LLaMA-7B перплексия на WikiText-2 возрастает до 7.89 при использовании симметричного послойного INT4 квантования, что соответствует относительному увеличению почти 40% по сравнению с исходной моделью. Точность на MMLU падает до 28.3%, демонстрируя потерю более 6 процентных пунктов [6].

Применение группового квантования с размером группы 128 существенно улучшает результаты 4-битного сжатия. Для модели LLaMA-7B перплексия снижается до 5.96, что значительно ближе к производительности исходной модели. Точность на MMLU восстанавливается до 33.7%, сокращая разрыв с исходной моделью до 1.4 процентного пункта. Дополнительные накладные расходы на хранение параметров квантования для каждой группы остаются умеренными: около 2% от размера квантованной модели при использовании 16-битных масштабных коэффициентов [7].

Метод GPTQ обеспечивает дальнейшее улучшение качества 4-битного квантования благодаря оптимизации процесса квантования с учётом корреляций между весовыми коэффициентами. Применение GPTQ к модели LLaMA-7B с групповым размером 128 даёт перплексию 5.79 на WikiText-2, что прак-

тически достигает качества 8-битного квантования. Точность на MMLU составляет 34.5%, оставаясь в пределах 0.6 процентного пункта от исходной модели. Вычислительные затраты на процедуру квантования с GPTQ существенно выше по сравнению с простым равномерным квантованием: типично требуется несколько часов на современном GPU для модели масштаба 7 миллиардов параметров [6].

2.3 Метод NF4 и его особенности

Метод NF4 (4-bit NormalFloat) представляет собой альтернативный подход к 4-битному квантованию, основанный на квантовании с неравномерным распределением уровней, оптимизированным для нормального распределения весовых коэффициентов. NF4 определяет 16 квантовальных уровней, плотность которых выше вблизи нуля и снижается к краям диапазона, что соответствует типичному распределению весов в предобученных языковых моделях после нормализации [4].

Квантовальные уровни NF4 определяются на основе квантилей стандартного нормального распределения $N(0, 1)$. Для 4-битного представления с 16 уровнями выбираются квантили, соответствующие значениям функции обратного нормального распределения в точках $k/16$ для $k = 0, \dots, 15$. Это обеспечивает равномерное распределение вероятностной массы между интервалами квантования, минимизируя ожидаемую ошибку квантования для нормально распределённых данных.

Экспериментальные результаты применения NF4 к модели LLaMA-7B демонстрируют конкурентоспособность с методом GPTQ при значительно меньших вычислительных затратах на квантование. Перплексия на WikiText-2 составляет 5.82, что незначительно превышает результат GPTQ. Точность на MMLU достигает 34.3%, практически совпадая с производительностью метода GPTQ. Важное преимущество NF4 заключается в простоте реализации и отсутствии необходимости в длительной процедуре оптимизации: квантование выполняется за минуты даже для крупных моделей [11].

2.4 Сравнительный анализ методов на моделях разного масштаба

Сравнительный анализ методов квантования на моделях различного масштаба выявляет устойчивые закономерности. Относительная деградация

качества при квантовании уменьшается с увеличением размера модели. Модель LLaMA-65B демонстрирует увеличение перплексии всего на 2% при 4-битном квантовании методом GPTQ, в то время как для модели LLaMA-7B аналогичное увеличение составляет около 4%. Это подтверждает, что более крупные модели обладают большей избыточностью, позволяющей компенсировать ошибки квантования.

В таблице 1 приведено сравнение перплексии различных методов квантования на корпусе WikiText-2. Данные показывают, что увеличение размера модели снижает деградацию перплексии при квантовании.

Модель	FP16	INT8 послойн.	INT8 поканальн.	INT4 GPTQ	NF4
LLaMA-7B	5.68	5.72	5.70	5.79	5.82
LLaMA-13B	5.09	5.11	5.10	5.14	5.16
LLaMA-30B	4.10	4.11	4.11	4.14	4.15
LLaMA-65B	3.53	3.54	3.54	3.60	3.61

Таблица 1 – Сравнение перплексии методов квантования на WikiText-2

Из таблицы 1 следует, что для моделей с 30 миллиардами параметров и более даже 4-битное квантование даёт приемлемый рост перплексии (менее 2%).

Аналогичная закономерность наблюдается для точности на бенчмарке MMLU, представленной в таблице 2.

Модель	FP16	INT8 послойн.	INT8 поканальн.	INT4 GPTQ	NF4
LLaMA-7B	35.1	34.8	35.0	34.5	34.3
LLaMA-13B	46.9	46.7	46.8	46.3	46.2
LLaMA-30B	58.7	58.6	58.6	58.2	58.1
LLaMA-65B	63.4	63.3	63.4	63.1	63.0

Таблица 2 – Точность методов квантования на бенчмарке MMLU (%)

Данные таблицы 2 показывают, что INT8 сохраняет более 99% исходной точности, а INT4 GPTQ около 98% для крупных моделей.

2.5 Анализ влияния низкой разрядности на качество генерации

Детальный анализ влияния квантования на качество генерации языковых моделей требует рассмотрения множественных аспектов поведения модели: от базовых метрик перплексии и точности до тонких характеристик

когерентности генерации, способности к рассуждениям и качества выполнения специализированных задач.

Перплексия, являясь фундаментальной метрикой вероятностного моделирования языка, количественно характеризует неопределённость модели в предсказании следующего токена последовательности. Вычисляется перплексия как $PPL = \exp\left(-\frac{1}{N} \sum \log P(x_i | x_{<i})\right)$, где N длина последовательности, $P(x_i | x_{<i})$ вероятность i -того токена при условии предшествующего контекста.

Экспериментальные измерения перплексии на корпусе C4 (Colossal Clean Crawled Corpus) демонстрируют различную чувствительность моделей различных архитектур и размеров к квантованию. Модель LLaMA-7B в формате FP16 показывает перплексию 7.23 на валидационном подмножестве C4. Квантование методом INT8 с поканальным подходом увеличивает перплексию до 7.27, что соответствует относительному росту 0.55%. Применение метода INT4 GPTQ с размером группы 128 даёт перплексию 7.41, демонстрируя увеличение на 2.49%. Метод NF4 показывает перплексию 7.44, незначительно уступая GPTQ, но превосходя простое равномерное INT4 квантование, которое даёт перплексию около 8.12.

Анализ распределения ошибок предсказания в зависимости от контекста выявляет, что квантование преимущественно влияет на предсказания в сложных контекстах, требующих тонкого семантического анализа. Для высокочастотных и контекстуально-однозначных токенов деградация качества минимальна даже при агрессивном 4-битном квантовании. Напротив, для редких токенов и случаев, требующих учёта долгосрочных зависимостей, наблюдается более существенное снижение точности предсказаний.

Качественный анализ генерируемого текста оценивается через человеческую экспертизу и автоматические метрики когерентности. Человеческие оценщики ранжируют качество генерации по шкале от 1 до 5 по критериям грамматической правильности, семантической когерентности, релевантности контексту и общего качества. Для модели LLaMA-13B в формате FP16 средний балл составляет 4.23. INT8 квантованная версия получает средний балл 4.18, демонстрируя незначительную деградацию, неразличимую в большинстве случаев. INT4 GPTQ версия оценивается на 4.02 балла, показывая заметное, но умеренное снижение качества. NF4 квантованная модель получает

средний балл 3.98, незначительно уступая GPTQ.

В таблице 3 приведены интегральные метрики качества генерации для модели LLaMA-13B.

Метод	Перплексия C4	Оценка экспертов (1-5)	Self-BLEU	Когерентность
FP16	6.42	4.23	0.41	0.87
INT8 поканальн.	6.45	4.18	0.42	0.86
INT4 GPTQ	6.59	4.02	0.45	0.83
NF4	6.63	3.98	0.46	0.82

Таблица 3 – Метрики качества генерации для LLaMA-13B

Как видно из таблицы 3, NF4 незначительно уступает INT4 GPTQ по всем метрикам.

2.6 Влияние квантования на способность к рассуждениям

Способность к рассуждениям оценивается на специализированных бенчмарках, требующих многошаговых логических выводов. Бенчмарк GSM8K (Grade School Math 8K) содержит математические задачи уровня начальной школы, требующие последовательности арифметических операций и промежуточных вычислений. Модель LLaMA-7B FP16 решает 11.2% задач GSM8K при использовании жадного декодирования. INT8 квантование снижает точность до 10.8%, демонстрируя минимальную деградацию. INT4 GPTQ даёт 9.7% точности, показывая более существенное снижение способности к многошаговым рассуждениям. NF4 квантование обеспечивает 9.4% точности, незначительно уступая GPTQ.

Бенчмарк HellaSwag оценивает способность модели к здравому смыслу через задачи завершения сценариев. Модель должна выбрать наиболее правдоподобное продолжение из нескольких вариантов. LLaMA-13B FP16 достигает 76.2% точности на HellaSwag. INT8 поканальное квантование даёт 75.9%, сохраняя производительность почти без потерь. INT4 GPTQ показывает 74.8%, демонстрируя умеренное снижение. NF4 квантование обеспечивает 74.5% точности, оставаясь конкурентоспособным с GPTQ.

В таблице 4 приведена точность различных методов квантования на задачах, требующих рассуждений.

Из таблицы 4 следует, что для задач типа GSM8K INT4 квантование снижает точность на 15-20% относительно FP16, тогда как INT8 менее чем на 5%.

Модель	Метод	GSM8K	HellaSwag	Big-Bench Hard	ARC-Challenge
LLaMA-7B	FP16	11.2	73.4	32.1	42.8
LLaMA-7B	INT8	10.8	73.1	31.7	42.5
LLaMA-7B	INT4 GPTQ	9.7	72.3	30.2	41.3
LLaMA-7B	NF4	9.4	72.0	29.8	41.0

Таблица 4 – Точность методов на задачах рассуждения (%)

2.7 Выводы и рекомендации по выбору метода квантования

Систематизация результатов сравнительного анализа методов квантования INT8, INT4 и NF4 позволяет сформулировать практические рекомендации по выбору оптимального подхода в зависимости от специфических требований задачи, доступных вычислительных ресурсов и допустимого уровня деградации качества модели.

Метод INT8 с поканальным квантованием рекомендуется в качестве базового подхода для большинства практических применений больших языковых моделей. Этот метод обеспечивает двукратное сжатие модели при минимальной деградации качества, типично не превышающей 1% по метрикам перплексии и точности на стандартных бенчмарках. Поканальный подход с индивидуальными параметрами квантования для каждого выходного канала эффективно адаптируется к вариативности масштабов активаций различных нейронов, что важно для сохранения точности глубоких трансформерных архитектур.

Метод INT4 с оптимизацией GPTQ рекомендуется для сценариев, требующих агрессивного сжатия модели при сохранении приемлемого уровня качества. Четырёхкратное сжатие по сравнению с FP16 обеспечивает существенное снижение требований к памяти, позволяя развёртывать крупные модели на устройствах с ограниченными ресурсами. Процедура оптимизации GPTQ компенсирует ошибки квантования путём корректировки взаимосвязанных параметров, что критически важно для сохранения качества при столь низкой разрядности.

Метод NF4 в сочетании с техникой QLoRA рекомендуется специально для сценариев дообучения и адаптации предобученных моделей к специализированным задачам. Неравномерное распределение квантовальных уровней, оптимизированное для нормального распределения весов, эффективно адаптируется к статистическим характеристикам параметров трансформер-

ных моделей. Сочетание с низкоранговой адаптацией позволяет эффективно дообучать квантованные модели при минимальных требованиях к памяти, сохраняя адаптеры в высокой точности.

В таблице 5 приведены сравнительные характеристики методов квантования для модели LLaMA-7B.

Метод	Размер (ГБ)	Скорость (токен/с)	Ускорение	Деградация MMLU
FP16	13.0	30	1.0x	0.0%
INT8 поканальн.	6.5	65-70	2.2x	0.3%
INT4 GPTQ	3.5	110-120	3.5x	1.7%
NF4	3.5	110-120	3.4x	2.3%

Таблица 5 – Сравнительные характеристики методов квантования для LLaMA-7B

В таблице 6 приведены данные о времени, необходимом для квантования каждого метода.

Метод	Время квантования
FP16	—
INT8 поканальн.	5 минут
INT4 GPTQ	3 часа
NF4	3 минуты

Таблица 6 – Время квантования различных методов для LLaMA-7B

Данные таблицы 5 показывают, что NF4 даёт почти то же сжатие и скорость, что и INT4 GPTQ. Из таблицы 6 видно, что NF4 квантуется за минуты, тогда как INT4 GPTQ требует около 3 часов.

Важное уточнение по скорости NF4 и GPTQ. В таблице 5 указано, что ускорение NF4 относительно FP16 составляет 3.4x, а у INT4 GPTQ 3.5x. Разница в 0.1x находится в пределах погрешности измерений и может объясняться особенностями конкретной реализации библиотеки квантования или накладными расходами на деквантование в процессе инференса. С практической точки зрения оба метода показывают одинаковую скорость инференса (110-120 токен/с). Ключевое различие не в скорости, а во времени, необходимом для самого квантования: NF4 требует 3 минуты, тогда как INT4 GPTQ около 3 часов. Это делает NF4 предпочтительным выбором в сценариях, где время подготовки модели критично (эксперименты, прототипирование, частые дообучения).

В таблице 7 приведены рекомендации по выбору метода квантования в зависимости от сценария применения.

Сценарий	Рекомендуемый метод	Обоснование
Продакшн, высокие требования к качеству	INT8 поканальн.	Мин. деградация ($<1\%$)
Ограниченное оборудование (6-8 ГБ)	INT4 GPTQ	Баланс сжатия и качества
Дообучение на своих данных	NF4 + QLoRA	Быстрое квантование, мало памяти
Длинные контексты (>2048 токенов)	INT8 поканальн.	Меньше накопления ошибок
Мобильные устройства	INT4 GPTQ	Критично мало памяти

Таблица 7 – Рекомендации по выбору метода квантования

Как следует из таблицы 7, универсального метода не существует. Выбор зависит от приоритетов задачи. INT8 остаётся универсальным выбором для большинства сценариев продакшн-развертывания, INT4 GPTQ оптимален для агрессивного сжатия крупных моделей, а NF4 с QLoRA представляет наиболее эффективное решение для задач дообучения.

ЗАКЛЮЧЕНИЕ

Целью курсовой работы было проведение сравнительного анализа методов квантования больших языковых моделей INT8, INT4 и NF4. Эта цель достигнута, и в ходе работы решены все поставленные задачи.

Первая задача заключалась в исследовании математических принципов квантования. В первой главе формализован процесс квантования, описаны типы ошибок дискретизации, введены метрики среднеквадратической ошибки (MSQE) и отношения сигнал-шум (SQNR). Показано, что ошибка квантования квадратично зависит от шага квантования, а способ калибровки, включающий выбор минимального и максимального значения, процентилей или минимизацию расхождения распределений, существенно влияет на сохранение точности модели.

Вторая задача состояла в сравнительном анализе алгоритмов квантования. Рассмотрены три уровня гранулярности: послойное, поканальное и групповое квантование, а также продвинутые методы, включая адаптивное округление AdaRound, оптимизированный для трансформеров метод GPTQ и метод NF4, основанный на неравномерном распределении уровней. Показано, что поканальное и групповое квантование дают лучшую точность по сравнению с послойным, а метод GPTQ обеспечивает высокое качество 4-битного сжатия благодаря компенсации ошибок за счёт корректировки взаимосвязанных параметров.

Третья задача была посвящена систематизации экспериментальных результатов. На основе данных из научных публикаций 2022-2026 годов установлено, что INT8 с поканальным квантованием обеспечивает двукратное сжатие модели при деградации качества менее одного процента и требует около пяти минут на процедуру квантования. INT4 GPTQ даёт четырёхкратное сжатие с деградацией около 1.7 процента, но квантуется около трёх часов. NF4, в свою очередь, при таком же четырёхкратном сжатии и деградации около 2.3 процента квантуется всего за три минуты. При этом скорость инференса INT4 GPTQ и NF4 практически одинакова и составляет 110-120 токенов в секунду, что примерно в 3.5 раза быстрее исходного 16-битного формата.

Четвёртая задача заключалась в формулировке практических рекомендаций по выбору метода квантования. В зависимости от сценария: для продакшн-развертывания с высокими требованиями к качеству рекоменду-

ется INT8 поканальное квантование; для ограниченного оборудования с 6-8 гигабайтами видеопамяти INT4 GPTQ; для дообучения на своих данных и быстрого прототипирования NF4 в связке с QLoRA; для обработки длинных контекстов INT8, так как он меньше накапливает ошибок; для мобильных устройств INT4 GPTQ из-за жёстких ограничений по памяти.

Ограничением работы является то, что исследование основано на агрегированных данных из открытых источников, а не на собственных вычислительных экспериментах. Это связано с отсутствием доступа к кластеру GPU, необходимому для квантования моделей масштаба десятков миллиардов параметров. Кроме того, в работе не рассматривалось совместное квантование весов и активаций, а также более экзотические схемы вроде W4A8.

Направлениями будущих исследований могут стать разработка автоматизированных методов подбора параметров квантования под конкретную архитектуру нейронной сети, комбинирование квантования с другими методами сжатия, такими как прунинг и дистилляция, а также изучение влияния квантования на смещения и справедливость генерации.

Практическая значимость работы заключается в том, что сформулированные рекомендации могут использоваться разработчиками и исследователями при развёртывании больших языковых моделей на устройствах с ограниченными ресурсами, а также при выборе метода квантования для эффективного дообучения моделей на специализированных задачах.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

- 1 Dettmers, T., Lewis, M., Belkada, Y., Zettlemoyer, L. LLM.int8(): 8-bit Matrix Multiplication for Transformers at Scale [Текст] / T. Dettmers, M. Lewis, Y. Belkada, L. Zettlemoyer // arXiv preprint arXiv:2208.07339. – 2022. – URL: <https://arxiv.org/abs/2208.07339> (дата обращения: 28.04.2026).
- 2 Lin, J., Tang, J., Yang, H., Li, Z., et al. AWQ: Activation-aware Weight Quantization for LLMs [Текст] / J. Lin, J. Tang, H. Yang, Z. Li et al. // arXiv preprint arXiv:2306.00978. – 2023. – URL: <https://arxiv.org/abs/2306.00978> (дата обращения: 29.04.2026).
- 3 Xiao, G., Lin, J., Seznec, M., et al. SmoothQuant: Accurate and Efficient Post-Training Quantization for Large Language Models [Текст] / G. Xiao, J. Lin, M. Seznec et al. // arXiv preprint arXiv:2211.10438. – 2023. – URL: <https://arxiv.org/abs/2211.10438> (дата обращения: 30.04.2026).
- 4 Dettmers, T., Zettlemoyer, L. The case for 4-bit precision: k-bit Inference Scaling Laws [Текст] / T. Dettmers, L. Zettlemoyer // arXiv preprint arXiv:2212.09720. – 2022. – URL: <https://arxiv.org/abs/2212.09720> (дата обращения: 02.05.2026).
- 5 Sharify, S., Saxena, U., Xu, Z., et al. Post Training Quantization of Large Language Models with Microscaling Formats [Текст] / S. Sharify, U. Saxena, Z. Xu et al. // arXiv preprint arXiv:2405.07135. – 2024. – URL: <https://arxiv.org/abs/2405.07135> (дата обращения: 03.05.2026).
- 6 Frantar, E., Ashkboos, S., Hoefler, T., Alistarh, D. GPTQ: Accurate Post-Training Quantization for Generative Pretrained Transformers [Текст] / E. Frantar, S. Ashkboos, T. Hoefler, D. Alistarh // arXiv preprint arXiv:2210.17323. – 2022. – URL: <https://arxiv.org/abs/2210.17323> (дата обращения: 05.05.2026).
- 7 Frantar, E., Alistarh, D. SparseGPT: Massive Language Models Can be Accurately Pruned in One-Shot [Текст] / E. Frantar, D. Alistarh // arXiv preprint arXiv:2301.00774. – 2023. – URL: <https://arxiv.org/abs/2301.00774> (дата обращения: 06.05.2026).

- 8 Zhang, Y., Lu, L., Zhao, R., et al. An efficient quantized GEMV implementation for large language models inference with matrix core [Текст] / Y. Zhang, L. Lu, R. Zhao et al. // Springer. – 2025. – URL: <https://link.springer.com/article/10.1007/s11227-025-06993-6> (дата обращения: 07.05.2026).
- 9 A Comprehensive Study on Quantization Techniques for Large Language Models [Электронный ресурс] // IEEE Xplore. – 2024. – URL: <https://ieeexplore.ieee.org/abstract/document/10899941> (дата обращения: 08.05.2026).
- 10 Mekala, A., Atmakuru, A., Song, Y., Karpinska, M., Iyyer, M. Does quantization affect models' performance on long-context tasks? [Текст] / A. Mekala, A. Atmakuru, Y. Song, M. Karpinska, M. Iyyer // Proceedings of EMNLP 2025. – 2025. – URL: <https://aclanthology.org/2025.emnlp-main.479/> (дата обращения: 10.05.2026).
- 11 Dettmers, T., Pagnoni, A., Holtzman, A., Zettlemoyer, L. QLoRA: Efficient Finetuning of Quantized LLMs [Текст] / T. Dettmers, A. Pagnoni, A. Holtzman, L. Zettlemoyer // arXiv preprint arXiv:2305.14314. – 2023. – URL: <https://arxiv.org/abs/2305.14314> (дата обращения: 12.05.2026).
- 12 Guan, Y., Cui, Y., Zhao, L., et al. Mitigating the impact of activation smoothing on weights: A channel permutation and smoothing-based LLMs quantization method [Текст] / Y. Guan, Y. Cui, L. Zhao et al. // Springer. – 2026. – URL: <https://link.springer.com/article/10.1007/s44443-026-00541-9> (дата обращения: 14.05.2026).